



Hochschule Karlsruhe
Technik und Wirtschaft
UNIVERSITY OF APPLIED SCIENCES

Entwicklung eines Systems zur Bewertung von Beziehungen zwischen Personen aus einer CRM-Lösung

Bachelor Thesis
von

Benjamin Tenke

An der Fakultät für Wirtschaftsinformatik
Matrikel-Nr: 33227

Erstgutachter:

Prof. Dr. Thomas Morgenstern

Zweitgutachter:

Prof. Dr. Andreas Schmidt

Betreuernder Mitarbeiter:

Michal Dvorak

Zweiter betreuender Mitarbeiter:

Ludwig Neer

Entwurf vom: 29. Oktober 2013

Ich versichere wahrheitsgemäß, die Arbeit selbstständig angefertigt, alle benutzten Hilfsmittel vollständig und genau angegeben und alles kenntlich gemacht zu haben, was aus Arbeiten anderer unverändert oder mit Abänderungen entnommen wurde.

Karlsruhe, DATE

.....
(Benjamin Tenke)

Inhaltsverzeichnis

1 Einführung	1
2 Grundlagen	5
2.1 NoSQL - Eine Einführung	5
2.1.1 Document Stores	5
2.1.2 Extensible Record Store	5
2.1.3 Key-Value-Store	6
2.1.4 Graph Datenbanken	6
2.1.5 NoSQL Theoretische Grundlagen	7
2.2 In Memory Datenbanken	8
2.3 Component Object Model	9
2.3.1 Architektur	10
2.3.2 COM-Client	10
2.3.3 COM-Server	10
2.3.4 COM-Schnittstelle	11
2.3.5 COM-Objekte	11
2.3.6 Interface Definition Language	11
3 Systemanalyse	13
3.1 CAS genesisWorld	13
3.1.1 Architektur	14
3.1.2 Präsentationsschicht & Logikschicht	14
3.1.3 Datenhaltungsschicht	15
3.2 Anforderungsanalyse	16
3.2.1 Funktionale Anforderungen	17
3.2.2 Nicht funktionale Anforderungen	17
3.3 Ermittlung relevanter Daten	18
4 Analyse ausgewählter Datenbanken	21
4.1 Datenbanken	21
4.1.1 CouchDB	21
4.1.2 MongoDB	22
4.1.3 Voldemort	22
4.1.4 Redis	23
4.1.5 HBase	23
4.1.6 Cassandra	23
4.1.7 VoltDB	24
4.1.8 H2	24
4.2 Gegenüberstellung	24
4.3 Auswahl einer Datenbank	26

5 Konzeption	29
5.1 Architektur	29
5.2 Technologien	31
5.3 Datenbankdesign	32
5.3.1 Konzeptionelles Design	32
5.3.2 Zugriffsstrukturen	34
5.4 Extract Transform Load Prozess	35
5.4.1 Extract	35
5.4.2 Transform	36
5.4.3 Load	36
5.5 Synchronisation des Datenbestandes	36
5.6 Darstellungskonzepte	37
6 Umsetzung	41
6.1 Aufbau der Server.war	41
6.2 Aufbau der Client.war	43
6.3 Erzeugung der Abfrage	45
6.4 ETL Prozess	46
6.5 Aktualisierung des Datenbestandes ...Progress	48
6.6 Oberfläche	49
7 Zusammenfassung	53
7.1 Ergebnisanalyse	53
7.2 Handlungsempfehlungen	54
7.3 Ergebnis	54
7.4 Ausblick	55
Literaturverzeichnis	57

Abbildungsverzeichnis

2.1	Beispiel einer Spalten Familie	6
2.2	Beispiele von Knoten und Kanten in einer Graph Datenbank	7
2.3	Bestandteile einer COM-Architektur	10
3.1	Schematische Darstellung der potenziellen Verknüpfungen	13
3.2	Schematische Darstellung der Architektur von CAS genesisWorld	14
3.3	Beispiel zur Benachrichtigung von PlugIns anhand eines Ablaufs bei einem Update	15
3.4	Funktionsweise von RelationTable anhand eines Beispiels	16
3.5	Auszug aus dem Schema des MSSQL 2008	19
5.1	Architektur des Systems	30
5.2	Neue Datenbankschema	33
5.3	Sequenzdiagramm eines Updates	37
5.4	Entwürfe der Oberfläche	38
6.1	Server Klassendiagramm	42
6.2	Client Klassendiagramm	44
6.3	Gewichtung der Zeit	46
6.4	Ausschnitt einer CSV-Datei mit Daten der Extraktion	47
6.5	Klassendiagramm Plugin	49
6.6	Oberfläche des Systems	50
6.7	Oberfläche des Systems	51
7.1	Abfragegeschwindigkeit Vergleich	54

Tabellenverzeichnis

4.1	Gegenüberstellung von den Charakteristika der Datenbanken	25
5.1	Vergleich des Speicherplatzverbrauchs	34
7.1	Abfragegeschwindigkeit Vergleich	53

1. Einführung

Es fällt Unternehmen immer schwerer sich über Produkte am Markt zu differenzieren, da sie immer homogener und damit austauschbarer werden. Dadurch werden Kunden- und Serviceorientierung besonders interessant für die Differenzierung vom Wettbewerb. Durch eine höherwertige und individuelle Kundebearbeitung können unter anderem für Unternehmen Wettbewerbsvorteile entstehen. Sämtliche Prozesse und Gestaltungen innerhalb des Unternehmens, die darauf abzielen, werden unter dem Terminus Customer Relationship Management(CRM) zusammengefasst. Unter dem CRM-Ansatz versteht man die Bearbeitung der Beziehung eines Unternehmens zu seinem Kunden. Dabei wird sich zum Ziel gesetzt die Aufgaben im Kundenmanagement schneller und effizienter zu bewältigen. CRM-Systeme bieten hierzu die technologische Unterstützung. Systeme dieser Art sind meist Datenbankanwendungen, die zur strukturierten Erfassung sämtlicher Daten beim Kundenkontakt dienen. In CRM-Systemen werden vier Hauptzielrichtungen fokussiert. Die Komponenten von verschiedenen CRM-Systemen mögen sich zwar unterscheiden, sie verfolgen jedoch alle die vier Hauptzielrichtungen. Zu einem erhofft man sich eine innovative und zielgerichtete Leistungsangebot Erstellung für den Kunden. Zum anderen wird eine Optimierung der eigenen Geschäftsprozesse im Kundenmanagement angestrebt. Weiterhin wird auf eine verbesserte Analyse, der Kundendaten gesetzt. Überdies setzen sich CRM-Systeme zum Ziel, die Marketing- und Vertriebsinstrumente zu unterstützen. Neben den operativen Komponenten zur Erfassung der Daten, besitzen einige CRM-Systeme analytische Komponenten. Diese werten die Kundendaten anwendungsorientiert aus und bieten Erkenntnisse über die Ausgestaltung der Geschäftsprozesse zum Kunden hin.

Die Grundlage von analytischen CRM-Systemen, ist die Aufbewahrung relevanter und für Analysen angepasster Daten, in einer Datenbank. Eine derartige Datenbank wird in der Literatur als Data-Warehouse bezeichnet. Mithilfe dessen man die steigende Datenflut und gleichzeitigem Informationsdefizit entgegenwirken möchte. Überdies wird eine Sicherstellung der Qualität, Integrität und Konsistenz angestrebt. Zu dessen Erreichung ist eine effiziente Bereitstellung und Verarbeitung der Daten notwendig. Diese Daten können anschließend, zur Durchführung von Analysen und Auswertungen herangezogen werden. Um solche Verfahren auf den Daten auszuführen, werden die Daten aus den operationalen Datenverarbeitungssystemen, in das Data-Warehouse überführt. Die Daten werden daher völlig unabhängig von den operativen Geschäftsprozessen, in neue, logische Zusammenhänge gesetzt. Dabei wird der Detaillierungsgrad der Daten verändert. In analytischen Systemen wird meistens durch eine Verdichtung der Daten, eine höhere Granularität erreicht. Speicherplatzbedarf, Verarbeitungsgeschwindigkeit und die Flexibilität eines Systems hängen

unmittelbar von dessen Granularität ab. Verdichtung können beispielsweise durch Bildung von Aggregaten oder Summierung verschiedener Datenobjekte erreicht werden. Aus technischer Sicht ist eine möglichst hoher Grad an Granularität von Vorteil. Den dadurch sinkt der Speicherplatzbedarf, sowie die Anzahl bzw. Größe der Indexdateien und der Aufwand in der Datenmanipulation.

Zielsetzung

Im Rahmen der Bachelorarbeit soll ein solches analytisches CRM-System entwickelt werden. In der CAS Software AG wurden bereits Ansätze im analytischen Umfeld verfolgt, jedoch konnte bis jetzt kein System akzeptable Verarbeitungsgeschwindigkeit liefern. Das zu entwickelnde System soll den Datenbestand von CAS genesisWorld zwar verwenden, allerdings parallel dazu betrieben werden. Das bedeutet, dass nicht auf vorhandenem aufgebaut werden kann, sondern vielmehr eine Neuentwicklung angestrebt wird. Damit erhofft man sich Altlästen, des bestehenden Systems, zu umgehen und bessere Resultate zu erzielen. Dabei sollen Entwicklungen der letzten Jahre, wie NoSQL- und In-Memory-Datenbanken, untersucht werden. Neben der Auswahl neuer Technologien, sind Extraktion und Transformation-Komponenten für das neue System zu entwickeln. Um den Umfang einzuschränken, soll ein einfaches Szenario festgelegt werden, welche eine konkrete Umsetzung ermöglicht. Neben der Anwendungslogik, die dem generieren der Abfragen dient, soll auch ein Client implementiert werden. Die Oberfläche des Clients sollte möglichst übersichtlich und einfach zu handhaben sein. Im Rahmen dieser Arbeiten sollen Erkenntnisse gewonnen werden, ob eine performante Umsetzung von analytischen Systemen auf dem operativen Datenbestand der CAS Software AG möglich ist. Dafür sollen Konzepte erstellt und umgesetzt werden. Mithilfe der Oberfläche soll anschließend überprüft werden, ob akzeptable Reaktionsgeschwindigkeiten zu erzielen sind.

Gliederung

Die weiteren Arbeiten untergliedern sich in folgende Abschnitte:

Grundlagen In Kapitel 2 werden Grundlagen vermittelt. Dabei wird zuerst auf das Thema NoSQL eingegangen. Dabei werden die unterschiedlichen Typen von NoSQL erläutert. Nachdem man einen Überblick über die Ausprägungen von NoSQL Datenbanken gewonnen hat, werden die einschlägige Begriffe erläutert. Die Begriffe werden bei der Evaluation der Datenbank des öfteren auftauchen und werden daher an dieser Stelle behandelt. Neben NoSQL, hat der Terminus In-Memory-Datenbank in den letzten Jahren an Interesse gewonnen. Daher wird ein kurzer Einblick in die Thematik gegeben. Neben den Datenbanken wird das Component Object Model erläutert. Grundlagen in diesem Bereich verschaffen einen guten Überblick über die Technologien, die in CAS genesisWorld eingesetzt werden.

Analyse In Kapitel 3 wird eine Analyse des bestehenden durchgeführt. Dabei wird die Architektur, sowie einzelne relevante Bestandteile von CAS genesisWorld untersucht. Weiterhin werden relevante Teile des Datenbestandes ermittelt, die im neuen System benötigt werden. Außerdem werden in dem Kapitel die Anforderungen an das neue System erhoben.

Evaluation Die Untersuchung, Gegenüberstellung und Auswahl einer geeigneten Datenbank wird im Kapitel 4.1 behandelt. Bei der Untersuchung der Datenbanken werden Ihre Eigenschaften sowie stärken und schwächen näher beschrieben. Weiterhin wird bei der Gegenüberstellung eine feste Anzahl an Eigenschaft festgelegt, anhand derer verglichen wird. Anschließend wird unter Beachtung der Anforderungen eine Datenbank ausgewählt und erörtert warum die anderen nicht genommen wurden.

Konzeption In der Konzeption wird die Architektur des neuen Systems entworfen. In Kapitel 5 wird zuerst eine grobe Architektur entworfen. Aufbauend auf dieser werden die einzelnen Bestandteile, in einer höhere Granularität ausgearbeitet. Neben der Architektur und den einzelnen Komponenten, werden die Technologien für die Umsetzung bestimmt.

Umsetzung In Kapitel 6 wird auf die Umsetzung der Planungen eingegangen. Dabei wird auf einer Abstraktionsebene beschrieben, wie die Implementierungen arbeiten. Es wird bewusst auf den Einsatz von Code verzichtet, um eine besseres Verständnis über die Logik und die Struktur zu gewinnen.

Ergebnis ...

2. Grundlagen

Diese Kapitel beschäftigt sich großteils mit dem Terminus NoSQL. Es wird auf die Bedeutung des Begriffs eingegangen, sowie die verschiedene Datenbank-Ausprägungen behandelt. Überdies werden grundlegende Begriffe aus dem NoSQL Umfeld erläutert. Damit sollen für spätere Untersuchungen Grundlagen geschaffen werden. Zu denen auch eine Erklärung der In-Memory Datenbanken gehört. Neben den Datenbanken wird auf das Component Object Model(COM) eingegangen. Es stellt die Basis des CAS genesisWorld Anwendungsservers dar und ist der Ausgangspunkt für weiterführende Untersuchungen.

2.1 NoSQL - Eine Einführung

NoSQL ist keine Datenbank, noch nicht einmal ein Datenbanktyp. Der Terminus NoSQL fasst lediglich Datenbanken zusammen, die nicht dem Modell der relationalen Algebra folgen. Eines haben sie jedoch gemeinsam, die treibende Idee die zu Ihrer Entwicklung geführt hat. Die Entstehung der NoSQL Datenbanken ist auf die schlechte horizontale Skalierbarkeit von relationalen Datenbanken zurückzuführen. Verfügbarkeit und Skalierbarkeit sind unter gewissen Umständen wichtiger als Atomarität und Konsistenz. NoSQL Datenbanken lassen sich anhand ihres Datenmodells unterscheiden. Nach [Vai13] ist eine Klassifizierung in folgende Kategorien möglich:

2.1.1 Document Stores

Document Stores koppeln komplexe Datenstrukturen (Dokumente) mit einem eindeutigen Schlüssel. Der Datenzugriff findet dabei in der Regel über das HTTP-Protokoll mit REST-API oder über das Apache Thrift-Protokoll statt [ASK07]. In Documents Stores gibt es außerdem kein Schema. Statt jeden Datensatz in einer Zeile bestehend aus Spalten zu speichern, werden sie in einem Dokument abgelegt. Diese können als eine Datei auf dem Dateisystem betrachtet werden. Solche Dokumente können alle möglichen Daten aufnehmen und müssen dabei keinem Schema folgen. Obwohl die Daten schematisch sind, sind sie nicht frei von formellen Restriktionen. Die meisten der verfügbaren Datenbanken unter dieser Kategorie benutzen XML, JSON, BSON oder YAML. Document Stores eignen sich für den Einsatz von dynamischen Entitäten, die unregelmäßige Strukturen besitzen.

2.1.2 Extensible Record Store

Extensible Record Stores, auch Wide Column Stores und auf deutsch oft spaltenorientierte Datenbank genannt, speichern Daten mehrerer Einträge in Spalten anstatt in Zeilen. Jeder Eintrag einer Spalte besteht aus einem Namen, den Daten und einem Zeitstempel.

In Extensible Record Stores werden sogenannte Spalten Familien zur Gruppierung ähnlicher oder verwandter Inhalte verwendet. In Abbildung 2.1 ist eine solche Spalten-Familie zu sehen. Spalten Familien besitzen keine logische Struktur und geben somit kein Schema vor. Weiterhin können sie Millionen von Spalten beinhalten weshalb sie auch Wide Columns Stores genannt werden. Verwandte Spalten werden in Spalten-Familien durch eine von der Anwendung bereitgestellte Reihe von Schlüsseln identifiziert. Weiterhin muss in einer Spalten-Familie nicht jede Zeile aus den gleichen Spalten bestehen.

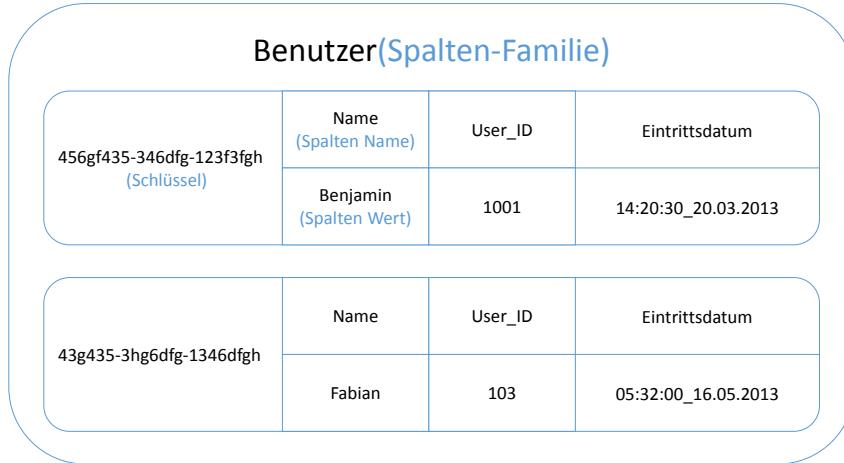


Abbildung 2.1: Beispiel einer Spalten Familie

Diese Architektur hat mehrere Vorteile. Meist weisen Werte in Spalten eine geringe Entropie auf, was sie besonders für Kompressionsverfahren geeignet macht. Die Verarbeitung der Anfragen wird ebenfalls beschleunigt, da keine unnötigen Informationen gelesen werden. Dies trifft in der Regel für Lese- und Schreibprozesse zu, wenn es um eine einzelne Spalte geht (in der Regel ein disk-seek). Die Geschwindigkeit nimmt beim Zugriff jedoch mit steigender Anzahl von Spalten ab.

2.1.3 Key-Value-Store

Key-Value-Stores sind die einfachsten NoSQL-Datenbanken. Sie ermöglichen die Speicherung von Werten mit einem Schlüssel. Im Gegensatz zu relationalen Datenbanken, haben Key-Value-Stores keine Kenntnis über die Daten der Werte und sind daher schemafrei. Grundsätzlich trifft das auf die meisten Umsetzungen von Key-Value-Stores zu. Redis und andere Umsetzungen sind allerdings in der Lage strukturierte Daten abzulegen und Ihre Felder zu indexieren. Dadurch wird eine Steigerung der Komplexität solcher Datenbank erreicht was jedoch nicht dazu führt, dass sie Verbund- oder Aggregat-Operatoren beherrschen.

2.1.4 Graph Datenbanken

Eine Graph Datenbank verwendet die Graphen Theorie zur Abbildung und Abfrage von Beziehungen [RWE13]. Im Grunde besteht eine solche Datenbank aus einer Menge von Knoten und Kanten. Jeder Knoten repräsentiert dabei eine Entität wohingegen Kanten Beziehungen oder Verbindung zwischen zwei Knoten darstellen. Abbildung 2.2 verdeutlicht dies in einem Beispiel. Knoten definieren sich durch einen sogenannten unique identifier, sowie durch die Anzahl abgehenden und/oder eingehenden Kanten und einer Menge von Attributen. Kanten werden wie Knoten definiert, nur dass sie Anstatt Kanten einen Start-

und End-Knoten besitzen. Graph-Datenbanken eignen sich gut für die Analyse von Verbindungen, weshalb sie oft zur Datengewinnung im Social Media Umfeld genutzt werden.

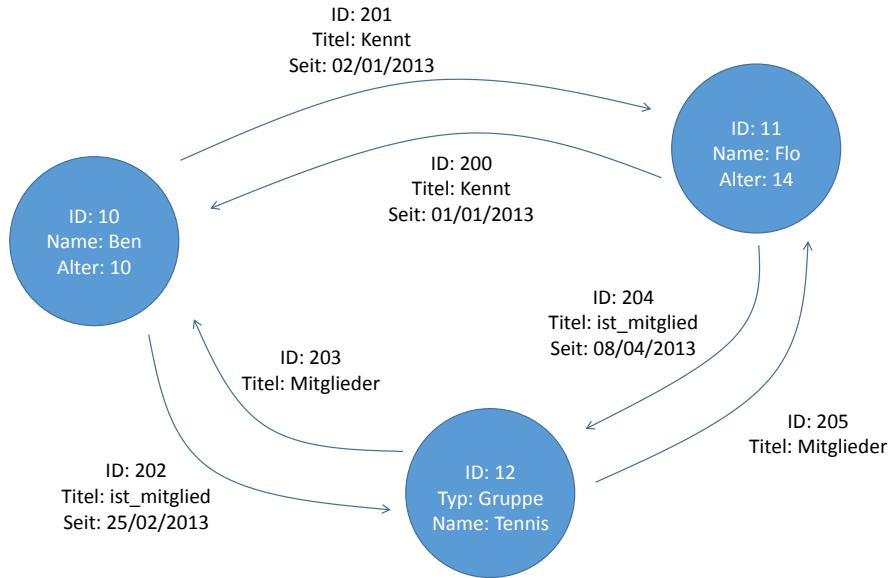


Abbildung 2.2: Beispiele von Knoten und Kanten in einer Graph Datenbank

2.1.5 NoSQL Theoretische Grundlagen

Im nachfolgenden werden Begriffe und Verfahren erläutert, die durch die NoSQL Bewegung geprägt wurden.

Replikation Replikation im Falle von verteilten Datenbanken bedeutet, dass ein Datenelement auf mehr als einem Knoten gespeichert ist. Dies ist sehr nützlich, um Lese-Leistungen der Datenbank zu erhöhen. Ermöglicht wird dies durch einen Load-Balancer, der Lesevorgänge über viele Maschinen verteilt. Neben den schnellen Lesezugriffen, wird durch den Load-Balancer auch die Ausfallsicherheit erhöht.

Fragmentierung Fragmentierung in der Datenbank ist der Zustand, bei dem die Daten in mehrere Fragmente aufgeteilt wurden. Diese können dann über viele Knoten verteilt werden. Die Datenpartitionierung kann beispielsweise mit einer konsistenten Hash-Funktion erfolgen, die auf dem Primärschlüssel der Datenelemente angewendet wird, um das zugehörige Fragment zu bestimmen.

Eventuelle Konsistenz Später in diesem Kapitel wird das CAP-Theorem eingeführt, was besagt das verteilte Datenbanken entweder stark konsistent oder verfügbar sein können. Folglich können die meisten NoSQL Datenbanken nur eventuelle Konsistenz bieten, eine abgeschwächte Art der starken Konsistenz. Starke Konsistenz bedeutet, dass alle mit der Datenbank verbundenen Prozesse immer die gleiche Version der Daten sehen. Eventuelle Konsistenz ist schwächer und garantiert nicht, dass jeder Prozess die selbe Version sieht.

Multiversion Concurrency Control (MVCC) MVCC ist eine effiziente Methode mehrere Prozesse auf dieselben Daten parallel zugreifen zu lassen, ohne eine Beschädigung der

Daten und der Möglichkeit von Deadlocks. Es ist eine Alternative zu den Lock-basierten Ansätzen, wobei jeder Prozess zuerst eine exklusive Sperre auf einem Datenelement anfordern muss, bevor es gelesen oder aktualisiert werden kann. Zu diesem Zweck werden intern verschiedene Versionen eines Objektes gehalten.

MapReduce MapReduce ist ein von Google entwickeltes Programmiermodell für verteilte Berechnungen und ist in einem Papier von Dean und Ghemawat [DG08] beschrieben. Anwendungen, die mit dem MapReduce-Framework geschrieben werden, können automatisch auf mehreren Computern verteilt werden ohne dass der Entwickler benutzerdefinierte Code für die Synchronisation und Parallelisierung schreiben muss. Es kann verwendet werden, um Aufgaben auf großen Datenmengen durchzuführen, die zu groß für eine einzelne Maschine zu handhaben wären.

Vector Clocks (Vektor Uhren) Vektor Uhren basieren auf der Arbeit von Lamport [Lam78] und werden von vielen Datenbanken verwendet, um festzustellen, ob ein Datenelement durch konkurrierende Prozesse verändert wurde. Jedes Datenelement besitzt eine Vektor Uhr, welche aus Tupeln mit verschiedenen Zeitpunkten besteht. Jeder Zeitpunkt stellt einen Prozess dar, der eine Modifikation an dem Datenelement vorgenommen hat. Jede Uhr beginnt bei Null und wird durch seinen Prozess bei jedem Schreibvorgang erhöht. Um den eigenen Wert der Uhr zu erhöhen, verwendet der Schreibprozess das Maximum aller Uhrenwerte im Vektor und erhöht sie um eins. Wenn zwei Versionen eines Elements zusammengeführt werden, können die Vektoruhren benutzt werden, um Konflikte zu erkennen. Wenn mehr als eine Uhr differenziert, muss ein Konflikt vorhanden sein. Wenn es keinen Konflikt gibt, kann die aktuelle Version durch den Vergleich der Maxima der Uhren ermittelt werden.

Das CAP-Theorem Das CAP-Theorem wurde von Dr. Brewer erstmal in einem Symposium [Dr.00] über den Trade-Off in verteilten Systemen eingeführt und wurde später von Gilbert und Lynch [GL02] formalisiert. Es besagt, dass in einem verteilten Datenspeichersystem nur zwei Merkmale aus Verfügbarkeit, Konsistenz und Partitionstoleranz garantiert werden können. Verfügbarkeit bedeutet in diesem Fall, dass die Clients in einem bestimmten Zeitraum immer Daten lesen und schreiben können. Eine partitionierte, verteilte Datenbank ist fehlertolerant gegen temporäre Verbindungsprobleme und ermöglicht es Partitionen über Knoten zu trennen. Ein System das tolerant partitioniert ist, kann nur starke Konsistenz durch Verminderungen in seiner Verfügbarkeit erreichen. Grund dafür ist, dass es zuerst sicherstellen muss, ob jeder Schreibvorgang abgeschlossen wurde, bevor er eine Replikation durchführen kann. Jedoch kann es vorkommen, dass in einer verteilten Umgebung, dass nicht möglich ist. Ursachen dafür können Verbindungsfehlern oder anderen temporären Hardware Problemen sein.

2.2 In Memory Datenbanken

Eine In-Memory-Datenbank (IMDB) ist ein Datenbank-Management-System, das in erster Linie den Hauptspeicher als Medium für die Datenablage benutzt. Eine IMDB wird auch als Hauptspeicher-Datenbank (MMDB) oder Echtzeit-Datenbank (RTDB) bezeichnet. IMDBs sind schneller als die Festplatten optimierte Datenbanken, denn sie führen weniger CPU-Befehle beim Lesen und Schreiben aus und ihre internen Optimierungsalgorithmen sind viel einfacher gestaltet. Einsatz finden sie vor allem in Anwendungen, bei denen Reaktionszeit von entscheidender Bedeutung ist. Mehrkernprozessoren, 64-bit Architekturen und gesunkene RAM Preise stellen die treibenden Faktoren in der Entwicklung solcher Systeme dar [Pla13].

Die hohe Performance dieser Systeme kann nicht durch simples verschieben der Daten in den Hauptspeicher erreicht werden. Bisherige Konzepte des Datenbankentwurfs müssen dabei neu überdacht werden. In herkömmlichen Datenbanken ist der Speicherverbrauch kein relevanter Faktor. In IMDBs hingegen ist der Einsatz von Speicherplatz sparenden Maßnahmen eine Notwendigkeit. Dictionary Encoding, Run-Length Encoding oder Cluster Encoding sind nur einige Techniken zur Reduktion des Speicherplatzverbrauches. Solche Techniken bieten sich vor allem in spaltenorientierten Systemen aufgrund der geringen Entropie innerhalb der Spalten an [AMF06]. Neben den Optimierungsansätzen in der Datenhaltung können Regeln formuliert werden, um nicht mehr verwendete Daten zu erkennen. Dabei kann z.B. zwischen aktiven Daten (Daten von nicht abgeschlossenen Geschäftsprozessen) und passiven Daten (Daten von abgeschlossenen Geschäftsprozessen) unterschieden werden [LLS13]. Wenn ein Geschäftsprozess in sich abgeschlossen ist, werden die Daten nur noch aus Datenvorhaltungsgründen aufbewahrt. Die zur Datenaufbewahrung benötigte Hauptspeicherkapazität, kann durch solche Regeln stark reduziert werden.

In-Memory Datenbanken, die den relationalen Ansatz verfolgen, besitzen zudem geänderte Query Optimizer. In herkömmlichen RDBMS sind Lese- und Schreiboperationen einer der wichtigsten Faktoren zur Bestimmung des optimalen Query Plans. Sie spielen jedoch eine stark untergeordnete Rolle in IMDB. Im Gegenzug nimmt die Reduktion von CPU-Zyklen einen höheren Stellenwert ein.

In traditionellen Datenbanken stellt das Wiederherstellen aufgrund des nicht flüchtigen Speichers kein Problem dar. IMDB müssen dagegen für den Fall eines Systemausfalls Snapshot Dateien anlegen. Diese werden zur Wiederherstellung des Datenbestandes benötigt. Snapshots sind Abbilder des aktuellen Datenbestandes. Um Rücksicht auf die Performance zu nehmen, werden die Snapshots entweder in Intervallen oder zu festgelegten Ereignissen erzeugt. Damit Veränderungen an Daten zwischen Snapshots nicht verloren gehen, werden Sie in Log Dateien zwischengespeichert. Zusammen mit den Snapshots dienen sie als Grundlage für die Datenwiederherstellung.

2.3 Component Object Model

Component Object Model (COM) ist ein binärer-Schnittstellenstandard für Software-Komponenten, der von Microsoft im Jahr 1993 eingeführt wurde [Loo01]. Er wird verwendet, um Interprozesskommunikation und dynamische Objekterstellung in einer Vielzahl von Programmiersprachen zu ermöglichen. Um zu verstehen was COM ist (und damit alle COM-basierten Technologien), muss einem klar sein, dass es sich nicht um eine objekt-orientierte Sprache, sondern um einen Standard handelt. Er definiert nicht die Sprache, Struktur oder Implementierungsdetails. Jeder dieser Entscheidungen werden dem Programmierer überlassen. Es spezifiziert lediglich ein Objekt Model und die Anforderungen an die Kommunikationen zwischen COM-Objekten und anderen Objekten. Es spielt dabei keine Rolle, ob Objekte sich im gleichen oder in unterschiedlichen Prozessen befinden. Sie können sogar auf unterschiedlichen Rechner laufen. Die Umsetzung in verschiedenen Sprachen ist durch die Umsetzung der Kommunikation in binären Maschinen Code möglich. Das führt dazu, dass COM des öfteren als binärer Standard referenziert wird.

COM bietet die Möglichkeit, auf viele Windows Funktionen zuzugreifen. Des weiteren ist COM die Basis für die OLE–Automation (Object Linking and Embedding) und ActiveX. Die Verwendung des COM-Standards bietet weiterhin folgende Vorteile:

- Sprachunabhängig
- Versionsunabhängig
- Plattformunabhängig

- Objektorientiert
- Ortsunabhängig
- Automatisiert

2.3.1 Architektur

COM basiert auf dem Client/Server-Prinzip. Wie in Abbildung 2.3 zu sehen, erzeugt ein COM-Client, eine COM-Komponente in einem so genannten COM-Server und nutzt die Funktionalität des Objektes über COM-Schnittstellen.

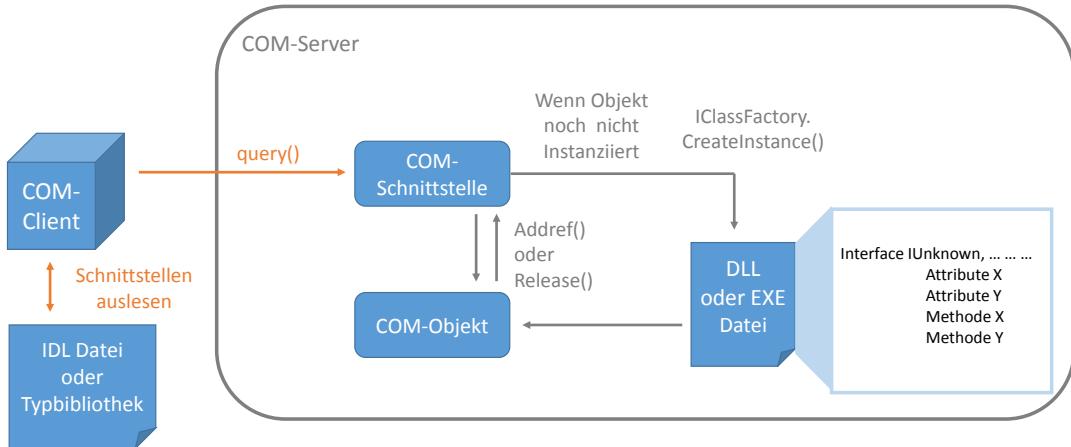


Abbildung 2.3: Bestandteile einer COM-Architektur

2.3.2 COM-Client

Der COM-Client stellt den Benutzer einer COM-Komponente dar. Die Nutzung der COM-Komponenten erfolgt über sogenannte Interfaces. Interfaces werden über Typbibliotheken veröffentlicht oder stehen in Form von Beschreibungen in der IDL (Interface Definition Language) zur Verfügung. Clients steht außerdem die Möglichkeit einer Query zur Verfügung, mithilfe derer festgestellt werden kann, ob ein Objekt das angefragte Interface unterstützt. Dabei wird lediglich die Query-Operation mit einer GUID als Parameter auf dem ausgewählten Objekt ausgeführt. Falls das Objekt das geforderte Interface unterstützt, liefert es den entsprechenden Pointer zum Interface zurück.

2.3.3 COM-Server

Ein COM-Server wird durch eine DLL oder ausführbare Datei realisiert, die eine COM-Komponente beinhaltet oder bereitstellt. Dabei unterscheidet man zwischen 3 Arten von COM-Servern. Die erste Variante ist der In-process-Server, der sich dadurch auszeichnet, dass er beim instanziieren einer COM-Komponente mit in den Prozess der Anwendung (COM-Client) geladen wird. Der Local Server hingegen tritt in Form eines ausführbaren Programmes auf, der COM-Komponenten implementiert. Dieser wird gestartet sobald ein COM-Client die COM-Komponente des Servers instanziiert. Die Kommunikation erfolgt über ein RPC-Protokoll. Die dritte Variante ist der Remote Server, der eingesetzt wird, sobald ein Netzwerk sich zwischen Client und Server befindet. Dabei wird DCOM (Distributed COM) verwendet, die eine spezielle Variante von COM darstellt. Unterscheiden tut sich DCOM lediglich durch den Einsatz eines vollständigen RPC-Protokolls, bei dem ein Protokollstack vorgeschaltet wird.

2.3.4 COM-Schnittstelle

COM ist eine Technologie, die es Objekten ermöglicht, über Prozess- und Rechnergrenzen hinweg so einfach wie in einem einzigen Prozess zu interagieren. COM ermöglicht dies durch die Angabe eines einzigen Weges (Schnittstelle), um die Daten eines Objektes zu verändern. Eine COM-Schnittstelle bezieht sich auf eine vordefinierte Gruppe von verwandten Funktionen, die eine Klasse implementieren. Eine Schnittstelle allerdings muss nicht unbedingt alle Funktionen die eine Klasse implementiert, unterstützen. Eine Schnittstellenimplementierung wird mit einem Objekt verbunden, sobald eine Instanz des Objekts erzeugt wird und die Implementierung die Dienste des Objekts bereitstellt. Zum Beispiel definiert ein hypothetisches Interface namens ISquare, eine Methode A. Diese Methode A soll das Quadrat einer Zahl zurückliefern. Ein Programmierer verwendet vielleicht integer als Datentyp und ein anderer Double. Auch das Quadrat könnte durch Multiplizieren zweier Zahlen berechnen werden oder durch rufen einer Funktion. Das alles spielt für den Client keine Rolle den der Verweis des Pointers im Speicher, den er letztendlich benutzt, ist durch das Interface definiert und ändert sich nicht.

Eine typische Vorgehensweise für die Entwicklung von Interfaces, ist es Funktionalitäten und Daten in logische Mengen zu gruppieren, die der Lösung eines Problems dienen. Ein Interface spiegelt dabei ein Verhalten innerhalb einer Problemdomäne wieder. Im Anschluss werden COM-Klassen durch entwickeln verschiedener Objekttypen gebildet. Objekttypen repräsentieren Entitäten, die verschiedene Kombinationen von Interfaces benutzen, basierend auf dem Verhalten, dass die Entität umsetzen soll. Dieser Prozess wird Interface basiertes Programmieren genannt. Zuletzt wird eine COM-Anwendung als eine Framework oder eine Hierarchie aller COM-Objekte umgesetzt.

2.3.5 COM-Objekte

Ein COM-Objekt bietet Funktionen des COM-Servers über ein Interface an. Durch die Implementierung IClassFactory.CreateInstance() kann eine Instanzierung im COM-Server vorgenommen werden. Zurückgeliefert wird dann eine Instanz der Klasse. COM-Objekte müssen nicht wieder freigegeben werden, da der COM-Server das selbst steuert. Bei der Instanziierung eines Objektes wird eine Referenzzähler hochgezählt. Dieser wird durch rufen von Release() wieder dekrementiert. Solange der Zähler ungleich 0 ist bleibt das Objekt erhalten.

2.3.6 Interface Definition Language

Die Syntax der Microsoft Interface Definition Language (MIDL) basiert auf der Syntax der Programmiersprache C. Das MIDL-Design gibt zwei verschiedene Dateien vor: die Interface Definition Language (IDL)-Datei und die Anwendungskonfigurationsdatei (ACF). Die IDL-Datei enthält eine Beschreibung der Schnittstelle zwischen dem Client und der Server-Programme. RPC Anwendungen benutzen die ACF-Datei, um die Eigenschaften von Interfaces, die spezifisch für die Hardware und Betriebssystem-Operatoren sind, zu beschreiben.

3. Systemanalyse

Zu Beginn der Arbeiten wird eine Systemanalyse zur Ermittlung des Ist- und Soll-Zustandes durchgeführt. Nach [Rup13] versteht man darunter das Beschreiben der vorhandenen und zukünftigen Systeme. Im Rahmen der Analyse ist die Kontextabgrenzung eines der wichtigsten Bestandteile. Dabei wird eine Abgrenzung zwischen dem Umfang und der Umgebung des Systems vorgenommen. Zuerst wird in Abschnitt 3.1 eine Ist-Analyse durchgeführt. In Abschnitt 3.2 wird auf die Anforderungen, die an das System gestellt werden eingegangen. Aufbauend auf den Anforderungen werden in Abschnitt 3.3, die für die Umsetzung relevanten Daten, ermittelt.

3.1 CAS genesisWorld

CAS genesisWorld ist eine Software, die Organisation und Zusammenarbeit in Kundenbeziehungen und zwischen Kollegen steigern soll. Alle Informationen bzw. Daten werden in CAS genesisWorld zentral gespeichert und sind so für alle verfügbar. Welche Daten ein Anwender sieht, hängt von seinen Rechten und Einstellungen ab. Die Daten, d. h. Termine, Aufgaben, Adressen, Dokumente usw. werden in CAS genesisWorld von den Nutzern gepflegt und aktuell gehalten. Darüber hinaus lassen sich wie in Abbildung 3.1 dargestellt, alle Daten beliebig miteinander verknüpfen. So werden zusätzliche Zusammenhänge deutlich und der Informationsgehalt erhöht sich. Ein Besprechungstermin lässt sich beispielsweise mit den Adressen, der Teilnehmer und dem Dokument der Tagesordnung verknüpfen.

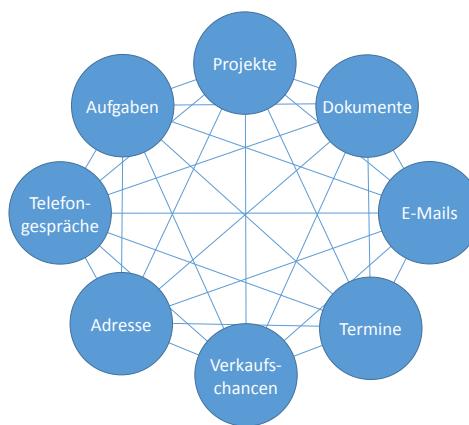


Abbildung 3.1: Schematische Darstellung der potenziellen Verknüpfungen

3.1.1 Architektur

Die N-Tier-Architektur von CAS genesisWorld, lässt sich in drei wesentliche Bereiche gliedern:

- Die Präsentationsclients umfassen alle Dienste, die Informationen in Bildschirm-Ansichten, dem Benutzern zur Verfügung stellen.
- Der Applikationsserver umfasst alle Dienste, die die Geschäftslogik kapseln, Änderungen protokollieren, Benutzerrechte prüfen und die aufbereiteten Informationen den Präsentationsdiensten zur Verfügung stellen.
- Die Datenbankschicht umfasst alle Dienste, die zur Datenhaltung selbst notwendig sind.

3.1.2 Präsentationsschicht & Logikschicht

CAS genesisWorld Clients existieren in Form einer 32bit Windows Anwendung, sowie als Mobile Client in Android und iOS. Die Kommunikation der Mobile Clients mit CAS genesisWorld findet über das REST-Protokoll statt [CSA13].

Die Funktionalität des CAS genesisWorld-Applikationsservers, wurde in Form von COM-Objekten implementiert. Damit stehen dessen Dienste auch Dritten zur Verfügung, die dadurch mit eigenen Applikationen die Informationen von CAS genesisWorld präsentieren oder weiterverarbeiten können. Als Basisdienste stehen der UserService und der DataService zu Verfügung. Für die Anmeldung und Rechteverwaltung ist der UserService zuständig. Der DataService hingegen, als zentraler Dienst für den Zugriff auf die CAS genesisWorld Daten. Die Schnittstelle des DataService wurde an Microsoft ADO angelehnt. Auf den Basisdiensten aufbauend existieren die Geschäftsdienste, in Form der Schnittstellen der BusinessServices. Diese bieten spezielle Funktionen zu den jeweiligen Anwendungsbe reichen.

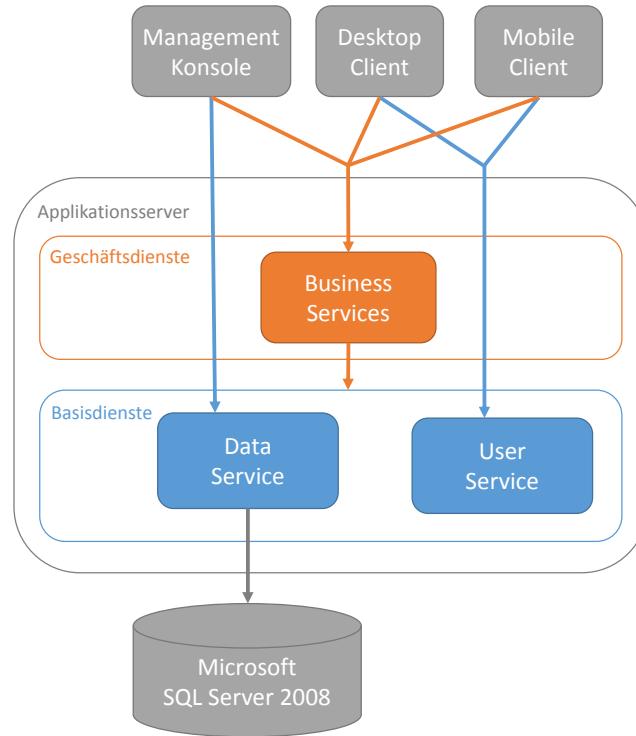


Abbildung 3.2: Schematische Darstellung der Architektur von CAS genesisWorld

Server-SDK-PlugIns Die Server-SDK-PlugIns bieten die Möglichkeit, die Datenverarbeitung um eine eigene Logik zu erweitern oder zu modifizieren.

Realisiert werden die PlugIns als COM-Objekte, die ein PlugIn-Interface namens IGWSDK-DataPlugIn implementieren. Das erstellte COM-Objekt wird im Server von CAS genesisWorld registriert. Der Server delegiert bei einer Datenoperation den Aufruf an die für den jeweiligen Datensatz-Typen registrierten PlugIns. In Abbildung 3.3 wird anhand eines Beispiels der Vorgang verdeutlicht.

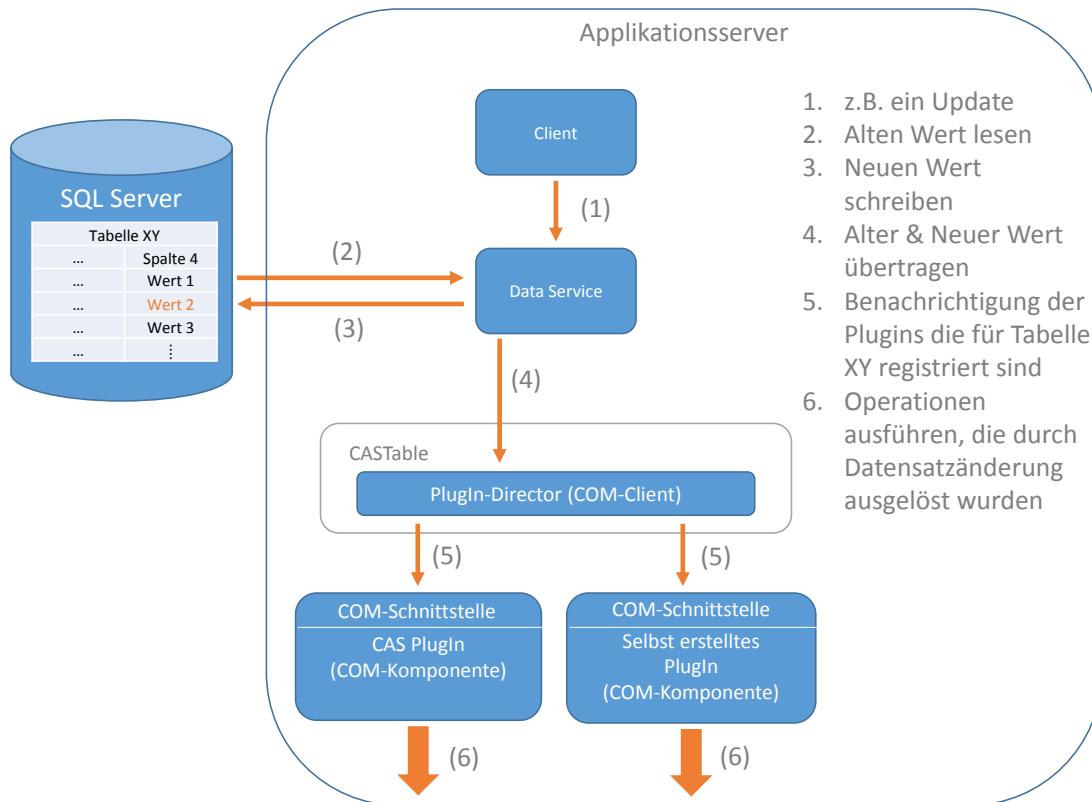


Abbildung 3.3: Beispiel zur Benachrichtigung von PlugIns anhand eines Ablaufs bei einem Update

Im Allgemeinen stehen in den COM-Schnittstellen der PlugIns, jeweils alle Felder eines Datensatz-Typen zur Verfügung, sowie die individuelle Teilmenge der Felder mit neuen Werten. In den PlugIns besteht damit die Möglichkeit, alte bzw. neue Werte von Feldern zu untersuchen und zu vergleichen und auf das Ergebnis zu reagieren.

Die Werte-Teilmenge des aktuell verarbeiteten Datensatzes kann verändert, d.h. erweitert oder reduziert werden und die Werte selber sind änderbar. Darüber hinausgehend sind auch automatisierte Aktionen realisierbar, die weitere Datensätze betreffen. So könnten z.B. abhängig von den Eingangswerten einer neu angelegten Adresse, neue Aufgaben angelegt und mit Inhalt versehen werden. Einige automatische Datenoperationen von CAS genesisWorld werden über CAS PlugIns realisiert, die mit den SDK-PlugIns verwandt sind.

3.1.3 Datenhaltungsschicht

Die Datenhaltungsschicht enthält einen Microsoft SQL Server 2008 (MSSQL). Der SQL Server ist ein relationales Datenbankmanagementsystem (RDBMS) von Microsoft, dass für

den Einsatz im Konzern Umfeld konzipiert wurde. MSSQL verwendet T-SQL (Transact-SQL), eine Erweiterungen von Sybase und Microsoft, die mehrere Funktionen zum SQL-Standard hinzufügt [Cor13]. Weiterhin unterstützt MSSQL standardisierte Datenbankschnittstellen, wie Open Database Connectivity (ODBC) und Java Database Connectivity (JDBC).

In den meisten relationalen Datenbanken werden Beziehungen über Primär-/ Fremdschlüsselbeziehungen hergestellt. In der CAS genesisWorld Datenbank werden nur Primärschlüssel eingesetzt. Die Beziehungen werden nicht wie sonst in mehreren Zwischentabellen realisiert, sondern in einer einzigen Tabelle, die RelationTable. In Abbildung 3.4 ist ein Beispiel zu sehen.

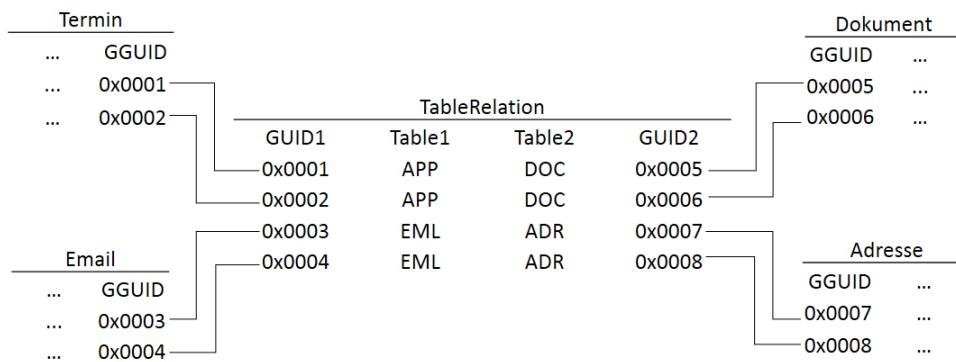


Abbildung 3.4: Funktionsweise von RelationTable anhand eines Beispiels

Die Spalten GUID1 und GUID2 beinhalten die jeweiligen Primärschlüssel, der in Beziehung zu setzenden Tabellen. Als Zuordnungsmerkmal für die GGUID's zu Ihren Tabellen, dienen die Spalten TableSign1 und TableSign2, deren Werte Kürzel der Tabellennamen sind. Möglich wird die Verknüpfung verschiedener Tabellen, durch einen besonderen Primärschlüssel. Dieser wird für jede neue Zeile generiert und ist in der gesamten Datenbank eindeutig. Er wird als Genesis Global Unique Identifier (GGUID) bezeichnet und ist ein 16 stelliger Binär-Wert. Alle Tabellen besitzen eine Spalte mit solchen Werten, was eine Datenintegrität in der gesamten Datenbank sicherstellt.

3.2 Anforderungsanalyse

Während der Anforderungsanalyse, wird ermittelt, welche Eigenschaften und Fähigkeiten das System zur Erreichung des Ziels benötigt. Wir unterscheiden bei der Einteilung der Anforderungen, zwischen Funktionalen und nicht Funktionalen. Wie der Name bereits verrätet, wird bei dem erst genannten, die Funktionalität des zu erstellenden Systems beschrieben. Unter die Kategorie der nicht Funktionalen fallen alle anderen Anforderungen.

Bevor wird auf die funktionalen und nicht funktionalen Anforderungen eingehen, wird die Fragestellung beschrieben, die mit dem System beantwortet werden soll. Mit dem zu entwickelndem System soll eine Art Ranking von Personen des Systems möglich sein. Dabei soll ermittelt werden können, welche Personen die Stärkste Beziehung, zu einer vorher bestimmten Person, besitzen. Der Nutzer soll dadurch erkennen, mit welchen Personen er am meisten Kontakt hat. Die Häufigkeit des Kontakts wird dabei anhand von fünf verschiedenen Kriterien ermittelt. Zu einem wird der E-Mail Verkehr, der Personen, für die Betrachtung herangezogen. Überdies werden die Telefonate unter den Personen miteinbezogen. Außerdem spielen nachvollziehbare Treffen(Termine) eine Rolle. Zwischen Personen

geteilte Dokumente werden auch als Kriterium festgesetzt. Das letzte Kriterium stellt die Verkaufschance gegenüber einem Kunden dar. Wie stark letztendlich die Beziehung zu einer anderen Person ist, wird anhand der Anzahl solcher Kriterien ermittelt.

3.2.1 Funktionale Anforderungen

Folgende funktionalen Anforderungen wurden erhoben:

- Ermittlung der Anzahl, der Beziehungen zwischen zwei Personen
- Ranking der Ergebnisse
- Rückgabewert soll den Gesamtwert der Abfrage beinhaltet, sowie die einzelnen Werte aus denen er sich zusammensetzt
- Begrenzung der Ergebnisse, durch die Anzahl der zurückgelieferten Personen
- Möglichkeit zum eingrenzen der Ergebnisse auf einen Zeitraum
- Ein- und Ausblenden von Suchkriterien, ohne eine neue Anfrage senden zu müssen
- Manuelles gewichten der Suchkriterien
- Gewichten der Zeitspannen durch den Nutzer
- Filterung der Ergebnismenge durch,
 - ausschließen von Personen oder eingrenzen auf Personen
 - Städte und/oder Länder der Personen
 - verringern auf Personen, die einem Unternehmen zugeordnet sind
 - beschränken auf Kontaktpersonen von Unternehmen
 - begrenzen auf Persönliche Kontakt Personen
 - vermindern um Personengruppen

3.2.2 Nicht funktionale Anforderungen

Folgende nicht funktionale Anforderungen wurden erhoben:

- In Memory Datenbanken in Betracht ziehen, bei Tauglichkeit einsetzen und testen
- Nur eine Rechner Instanz für Datenbank und Applikationsserver
- Antwortzeiten des Systems möglichst gering halten
- Beachtung der Portabilität, damit der entwickelte Prototyp einfach auf anderen Systemen installiert werden kann.
- Lose Kopplung zwischen Präsentationsschicht und Logikschicht
- Daten auf der Oberfläche graphisch aufbereitet darstellen; keine Konsolen Eingabe/-Ausgabe

3.3 Ermittlung relevanter Daten

Die Datenbank der CAS Software AG umfasst 398 Tabellen, die zusammen wiederum 11.620 Spalten beinhalten. Aufgrund einer fehlender Dokumentation, über die Umsetzung der darüberliegenden Anwendungsschicht und der Abwesenheit von definierten Beziehungen innerhalb der Datenbank, wurde ein eigenes Verfahren zur Ermittlung der Beziehungen entwickelt.

Für den Ausgangspunkt der Suche, wurde eine Tabelle namens SysUser verwendet. Sie beinhaltet jeden Benutzer des Systems. Ihre Eignung beruht auf der Annahme, dass bei der Bewertung von Beziehungen zwischen Personen, die Person selbst dabei immer den Ausgangspunkt der Suche darstellt. Aus Datenbanksicht bedeutet, dass zuerst eine Tupel der SysUser Tabelle mit Ihrer GGUID herangezogen wird. Die GGUID ist dabei der erste Wert, nachdem in der gesamten Datenbank gesucht wird. Sobald alle Tabellen gefunden wurden, die den Wert beinhalten, werden deren GGUIDs für die weitere Suche verwendet. Die Menge der Suche wird nach jedem Schritt, um die Teilmenge der bereits gefundenen Tabellen verringert. Die Suche wird abgebrochen, sobald die Suchmenge keine Werte mehr aufweist oder keine Tabellen mehr mit den entsprechenden Werten gefunden wurden. Durch dieses Vorgehen erhält man am Ende alle Beziehungen, aufbauend auf der Annahme, dass die GGUID als Referenzierungswert benutzt wurde. In Abbildung 3.5, ist ein schon auf das Wesentliche reduzierter Ausschnitt, des Ergebnisses zu sehen.

Von den ursprünglich 398 Tabellen sind nur noch 17 übrig geblieben, auf die im Weiteren Verlauf eingegangen wird. Alle Tabellen enthalten in der ursprünglichen Form wesentlich mehr Spalten und wurden der Übersicht halber entfernt. Tabelle SysUser besitzt drei Spalten, die von Bedeutung sind. Eine davon ist die GGUID, die im folgenden nicht mehr erwähnt wird, da Sie jede Tabelle enthält. Die OID wird für jeden Nutzer einmalig vergeben und wird in anderen Tabellen als Zuordnungsmerkmal verwendet. LoginName ist wie der Name schon sagt, der Benutzername des Nutzers und kann beim anmelden auf der Oberfläche, wieder verwendet werden.

Aufgrund der Anforderung, Filterung durch Gruppen, wurden die Tabellen SysGroup-Member und SysGroup hinzugezogen. SysGroup besitzt eine GID, die das Gleiche für Gruppen ist, wie die OID für Personen. Das Attribut GroupName, wird für die Anzeige an der Oberfläche benötigt. Mithilfe dessen der Nutzer erkennen kann, welche Gruppe er gerade ausgewählt hat. SysGroupMember stellt die Auflösungstabelle zwischen SysUser und SysGroup dar. Die Spalte GroupID beinhaltet Werte aus der SysGroup-GGUID Spalte. MemberID folgt dem gleichen Ansatz, mit den SysUser-GGUID Werten. In Hinsicht auf die Logikschicht, wird die Spalte InsertTimestamp für Veränderungen innerhalb der Gruppen benötigt.

Die Adress0 Tabelle wird für die restlichen Filter Anforderungen benötigt. Town1 und Country1 geben die Stadt sowie das Land an, in der die Person ansässig ist. Zur Ermittlung, ob eine Person eine Kontaktperson, Mitarbeiter oder eine Firma repräsentiert, werden die Attribute gwIsContact, gwIsEmployee und gwIsCompany benötigt. Name und ChristianName beinhalten den Vor- und Nachname der Person, welche bei der Zuordnung der Ergebnisse an der Benutzeroberfläche hilfreich sind. Vorausgreifend ist zu sagen, dass nicht alle Telefongespräche, über die dafür bestimmten Tabellen ermittelt werden können. Deswegen werden die Attribute PhoneFieldStr1-10 benötigt, mithilfe derer eine Zuordnung ermöglicht wird.

Die TableRelation enthält, wie in Abschnitt 3.1.3 behandelt, die Beziehungen der Datenbank. Auf das Szenario bezogen, wird für die GUID1 die GGUID der SysUser benutzt. Mithilfe der GUID2 können die mit der Person verknüpften Termine, Verkaufschanzen, Telefonate, Dokumente und Emails ermittelt werden. TableSign1 und TableSign2 werden zur Identifikation der jeweiligen Tabellen benötigt.

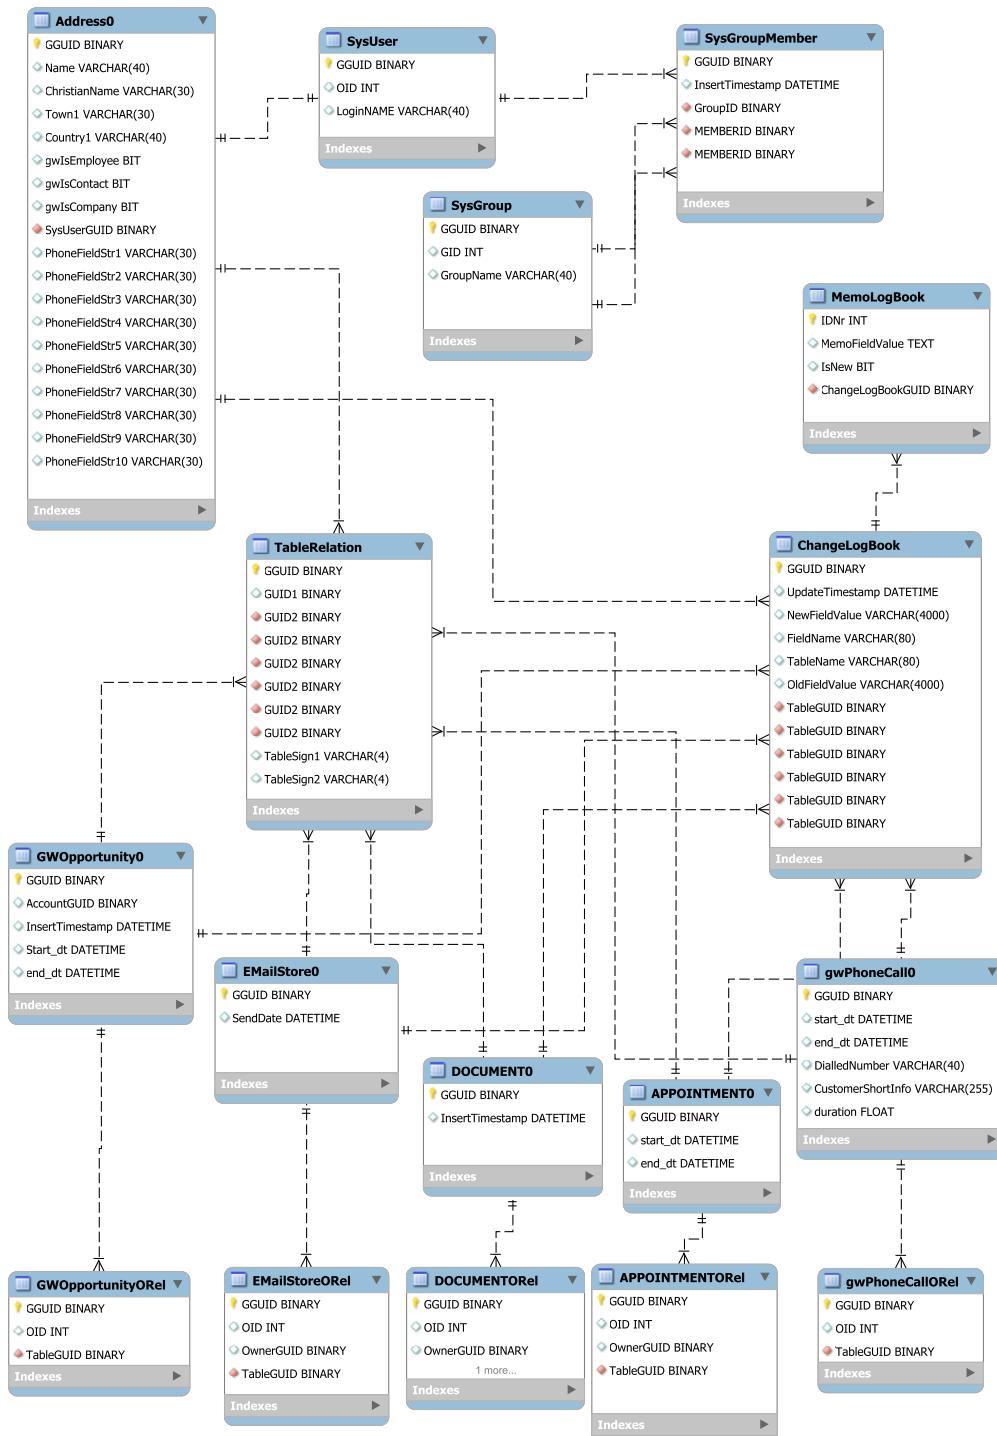


Abbildung 3.5: Auszug aus dem Schema des MSSQL 2008

GWOpportunity0 enthält alle Informationen zu Verkaufschancen. Das Attribut InsertTimestamp wird zur Feststellung des Erzeugungszeitpunktes benötigt. Start_dt und end_dt legen den Zeitraum der Verkaufschance fest. Der Besitzer einer Verkaufschance, wird über die AccountGUID bestimmt. Mit EMailStore0, Document0 Appointment0 und gwPhoneCall0 verhält es sich wie mit GWOpportunity0. Bei EMailStore0 ist zu erwähnen, dass SendDate zur zeitlichen Einordnung verwendet werden kann. Das Attribut DialledNumber der Tabelle gwPhoneCall0, wird zum Vergleich mit der in der Adresse hinterlegten Telefonnummer, benötigt. Zur Überprüfung ob das Telefonat über einen Tag hinausging, wird das Attribut duration herangezogen.

Bis jetzt galt die Annahme, dass alle Beziehungen über die TableRelation bestimmt werden können. Dies trifft allerdings nicht ganz zu. Dort werden nur, die an der Oberfläche manuell verknüpften Tabellen aufbewahrt. Die restlichen Beziehungen können aus den ORel-Tabellen ermittelt werden. Jeder dieser Tabellen enthält eine OID bzw. GID, die zur Bestimmung der beteiligten Personen und/oder Gruppen dienen.

Eine Betrachtung basierend auf Zeitspannen, impliziert Veränderungen der Daten über die Zeit gesehen. Um diese Änderungen zu erfassen, wird die Tabelle ChangeLogBook benötigt. NewFieldValue enthält den neuen Wert eines Feldes. Wohingegen OldFieldValue den alten Wert des Feldes enthält. Die Spalte des geänderten Wertes ist inFieldName hinterlegt. Der Name der Tabelle, ist der Spalte TableName zu entnehmen. Die Referenzierung auf eine Tupel wird in der Spalte TableGUID vorgenommen. Aus Gründen des Speicherplatzverbrauchs werden nur varchar Datentypen bei Zeichenfolgen verwendet. Varchar ist jedoch auf 4000 Zeichen limitiert. Falls Zeichenfolgen diese Grenze überschreiten, werden die in der Tabelle MemoLogBook abgelegt. Dort wird der Datentyp Text verwendet, der eine maximale Zeichenfolge von $2^{31}-1$ erlaubt.

4. Analyse ausgewählter Datenbanken

Ein Ziel der Bachelor Thesis ist hohe Performance in der Beantwortung der Benutzeranfragen zu erreichen. Die maßgebende Komponente ist in diesem Fall die Datenbank. Sie führt die zeitintensiven Ermittlungen, Berechnungen und Filterungen des Gesamtsystems durch. Um Anhaltspunkte für mögliche Kandidaten zu bekommen, sollen im folgenden eine Reihe bekannter Datenbanken vorgestellt und gegenübergestellt werden. Bei der Zusammenstellung wurde darauf geachtet, dass ein möglichst weites Spektrum unterschiedlicher Datenbanken ausgewählt wurde.

4.1 Datenbanken

Im folgenden werden nun einige Datenbanken vorgestellt. Dabei wird insbesondere versucht, einen guten Überblick über die Charakteristika der einzelnen Datenbanken zu geben. Der dahinter stehende Gedanken ist, dass der Vergleich und die Auswahl, besser nachvollziehbar werden.

4.1.1 CouchDB

CouchDB [Cou13] ist eine dokumentenorientierten Datenbank, die seit Anfang 2008 unter der Apache-Lizenz verbreitet wird. In CouchDB werden die Daten in Collections anstatt in Tabellen abgelegt. Collections bestehen aus einer Sammlung von unabhängigen Dokumenten. Jedes Dokument verwaltet seine eigenen Daten in einem freien Schema. Ein Dokument hat Feldwerte, die Datentypen (Text, numerisch oder boolean) oder Datenstrukturen (ein Dokument oder Liste) beinhalten. Abfragen werden mit "views" zum Filtern der Dokumente ausgeführt. Indizes sind in CouchDB B-Bäume, sodass die Ergebnisse sortiert und Wertebereich-Anfragen ausgeführt werden können. Abfragen können parallel über mehrere Knoten mit einem MapReduce Mechanismus verteilt werden. CouchDB erreicht Skalierbarkeit durch asynchrone Replikation, nicht durch Fragmentierung. Lesezugriffe können auf beliebigen Server stattfinden, wenn Aktualität keine Rolle spielt. Updates hingegen müssen an alle Server weitergegeben werden. CouchDB unterscheidet sich von anderen Systemen dadurch, dass es Eventual Consistency akzeptiert. Jeder Client erhält eine in sich selbst konsistente Ansicht der Datenbank. CouchDB implementiert Multi-Version Concurrency Control (MVCC) auf einzelne Dokumente, mit einer Sequenz-ID, die für jede Version eines Dokuments generiert wird. CouchDB benachrichtigt eine Anwendung, wenn jemand anderes das Dokument aktualisiert hat, seitdem es zuletzt auf der Datenbank abgelegt wurde. Die Anwendung kann dann versuchen, die Updates zu kombinieren oder das Update zu

wiederholen, um die Daten zu überschreiben. CouchDB erfüllt damit im lokalen Einsatz die ACID-Eigenschaften. Jede Transaktion ist eine in sich abgeschlossene Operation, die entweder ganz oder gar nicht ausgeführt wird. Es treten keine Seiteneffekte zwischen den Anfragen auf. Außerdem wird die Datenbank immer in einem konsistenten Zustand hinterlassen.

4.1.2 MongoDB

MongoDB ist ein in C++ geschriebener, Open Source Document Store [CD10]. Es besitzt einige Ähnlichkeiten mit CouchDB. Beide bieten Indizes auf Collections, sind lockless, und bieten einen Abfragemechanismus für Dokumente. Es gibt jedoch wichtige Unterschiede:

- MongoDB unterstützt automatische Fragmentierung, die Dokumenten über Server verteilt.
- Dynamische Abfragen mit automatischer Verwendung von Indizes, werden von MongoDB unterstützt. In CouchDB werden, durch das Schreiben von map-reduce-views, Daten indiziert und gesucht.
- CouchDB nutzt MVCC bei Dokumenten, MongoDB hingegen nutzt atomare Operation auf Feldern

MongoDB speichert Daten in einem JSON-ähnlichen, binären Format namens BSON. BSON unterstützt boolean, integer, float, Datum, String-und Binär-Typen. Client Treiber verschlüsseln die lokalen Dokumentdatenstrukturen in das BSON Format und senden es an den MongoDB Server. Weiterhin unterstützt MongoDB die GridFS Spezifikation für große binär Dateien, wie z.B. Filme oder Bilder. MongoDB unterstützt Master-Slave-Replikation mit automatischem Failover und Recovery. Replikation (und Wiederherstellung) basieren auf dem Prinzip der Fragmentierung. Collections werden über einen benutzerdefinierten Schlüssel automatisch fragmentiert. Die Replikation ist asynchron für höhere Leistung, jedoch können einige Updates bei einem Crash verloren gehen.

4.1.3 Voldemort

Projekt Voldemort [Vol13a] ist ein verteilter Key-Value-Store (entwickelt von LinkedIn), der ein hoch skalierbares Speicher-System zur Verfügung stellt. Voldemort repliziert sich durch automatisches partitionieren und anschließendes verteilen der Daten auf multiple Server. Jeder Server stellt einen unabhängigen Knoten im System dar, der für die Verwaltung seiner Daten verantwortlich ist. Dadurch existiert kein Single Point of Failure im Cluster. Ein solches Daten Model erlaubt eine Cluster Expansion, ohne eine Neuverteilung der Daten vornehmen zu müssen. In Voldemort können verschiedene Storage Systeme, wie BerkeleyDB oder MySQL eingesetzt werden.

Für die Ablage der Daten werden in Voldemort sogenannte Stores verwendet. Unterstützt werden lediglich Key-Value Ablagen. Jedoch können values komplexere Datenstrukturen wie Maps oder Listen beinhalten. Voldemort stellt vier verschiedene Operatoren zur Datenmanipulation bereit:

- PUT (Key,Value)
- GET (Key)
- MULTI-GET (Keys)
- DELETE (Key, Version)

Eine Möglichkeit für Range Scans ist dabei nicht vorhanden. Der Parameter Version, im DELETE-Operator, dient der Unterscheidung der Datensätze und ist auf das Verfahren zur Gewährleistung der Konsistenz zurückzuführen. Zur Gewährleistung der eventuellen Konsistenz werden Timestamps und die Vector Clock Technik eingesetzt. Neben der eventuellen Konsistenz, bietet Voldemort einen Betrieb mit starker Konsistenz an.

4.1.4 Redis

Redis [Seg13] ist ein In-Memory-, Key-Value-Store mit einer Option für Persistenz. Redis Datenmodell unterstützt Strings, Hashes, Listen, Mengen und sortierte Mengen. Obwohl Redis für In-Memory-Daten entworfen wurde, kann je nach Anwendungsfall ein (semi-) persistenter Bestand angelegt werden. Entweder durch Momentaufnahmen der Daten und anschließendes ablegen auf der Festplatte, in regelmäßigen Abständen oder durch Aufzeichnen eines Logs mit allen ausgeführten Operationen. Weiterhin kann Redis mit einem Master-Slave-Architektur repliziert werden. Genau wie andere Key-Value-Stores implementiert Redis insert, delete und lookup Operatoren. Weiterhin setzt Redis atomare Updates durch locking um.

4.1.5 HBase

HBase ist eine verteiltes, Open Source Column Store Datenbanksystem, welches auf Googles BigTable basiert [CDG⁺06]. HBase läuft auf Apache Hadoop und Apache ZooKeeper [HKJR10] und verwendet das Hadoop Distributed Filesystem (HDFS) [SKRC10], um Störung-Toleranz und Replikation zu bieten. Zeilen Operationen sind in HBase atomar, mit Sperren auf Zeilenebene und Transaktionen. Partitionierung und Verteilung sind transparent, da es keine Client-Seitiges Hashing oder feste Schlüsselräume wie in einigen NoSQL-Systemen gibt. Insbesondere stellt es lineare und modulare Skalierbarkeit, sowie streng konsistenten Datenzugriff und automatisches und konfigurierbares Fragmentierung von Daten zu Verfügung. Auf Tabellen können in HBase über eine API zugegriffen werden. Sie können jedoch auch als Ein- und Ausgang Daten für MapReduce-Jobs in Hadoop verwendet werden. Anwendungen speichern in HBase Daten in Tabellen, die aus Zeilen und Spalten Familien bestehen. Spalten Familien beinhalten wiederum Spalten. Darüber hinaus kann jede Zeile einen anderen Satz von Spalten beinhalten. Alle Spalten sind mit einem vom Benutzer bereitgestellten Schlüsselspalte indiziert und in Spalte Familien gruppiert.

4.1.6 Cassandra

Apache Cassandra ist eine verteilte Column Store Datenbank die von Facebook entwickelt wurde [LM10]. Sie ist eine Mischung aus Amazon Dynamo und Google BigTable, wodurch sie des öfteren als Hybrid zwischen Key-Value-Store und Column Store bezeichnet wird. Cassandra wurde entwickelt, um große Daten-Workloads über mehrere Knoten, ohne Single Point of Failure zu behandeln. Die Architektur ist von der Annahme geprägt, dass System- und Hardware-Fehler auftreten können und auch wirklich auftreten. Cassandra behandelt das Problem von Fehlern durch Verwendung eines Peer-to-Peer-System, in dem alle Knoten gleich sind und die Daten von allen Knoten des Clusters verteilt werden. Jeder Knoten tauscht Informationen über das Cluster im Sekunden Takt aus. Ein Commit-Log auf jedem Knoten fängt Schreibaktivität ab, um Datenhaltbarkeit zu gewährleisten. Daten werden auch auf eine In-Memory Struktur geschrieben, die memtable. Sobald die Speicherstruktur voll ist, werden die Daten in eine Datei auf die Festplatte geschrieben, auch SSTable genannt. Alle Schreibvorgänge werden automatisch aufgeteilt und in Cluster repliziert.

Cassandras Datenmodell basiert auf einem partitionierten Row-Store mit variabler Konsistenz. Zeilen werden in Tabellen organisiert, die erste Komponente des Primärschlüssels einer Tabelle, ist der Partition Schlüssel. Innerhalb einer Partition, werden Zeilen nach den

verbliebenen Spalten des Primärschlüssels geclustert. Andere Spalten können getrennt von dem Primärschlüssel indiziert werden. Was Cassandra von HBase unterscheidet sind Spalten, die in einer verschachtelten Weise in Spalte Familien gruppiert werden können.

Ein weiteres Unterscheidungsmerkmal stellt die Möglichkeit zur Angabe der Konsistenz Anforderung dar, die zum Zeitpunkt der Abfrage angebbar ist. Weiterhin ist Cassandra ein schreiborientiertes System, während HBase entwickelt wurde, um hohe Leistung für intensive Lese Workloads zu erzielen.

4.1.7 VoltDB

VoltDB [Vol13c] ist ein ACID-konformes, relationales In-Memory-Datenbanksystem, abgeleitet vom Forschungsprototyp H-Store [KKN⁺08]. Es basiert auf einer Shared-Nothing-Architektur und wurde entwickelt, um auf einem Cluster mit mehreren Knoten zu laufen. Dies wird erreicht, indem man die Datenbank in getrennte Partitionen aufteilt, bei dem jeder Knoten, Besitzer und Verantwortlicher für die jeweiligen Partitionen ist. Durch Verwendung von Stored procedures als Transaktionseinheit, werden Round-Trip-Messages zwischen SQL Anfragen verhindert. Die Anfragen werden seriell in einem einzigen Thread ausgeführt, sodass kein locking and latching mehr notwendig ist [Vol13b]. Die Daten werden im Arbeitsspeicher gehalten, was eine Ausführung ohne Netzwerkzugriff und I/O Vorgänge ermöglicht, falls die Daten nur auf einem Knoten liegen.

4.1.8 H2

H2 ist ein in Java geschriebenes relationales Datenbanksystem, dass im Jahre 2004 von Thomas Müller veröffentlicht wurde. Es wird unter der Eclipse Public License verbreitet und ist damit Open Source. H2 bietet neben den festplattenbasierten Tabellen, auch eine In-Memory Variante an. Tabellen können dabei dauerhaft oder temporär sein. Weiterhin beherrscht H2 referentielle Integrität, Transaktionen, Clustering, Datenkompression, Verschlüsselung und SSL. Die Datenbank kann im Embedded- oder Server-Modus betrieben werden.

4.2 Gegenüberstellung

Zur übersichtlichen Gegenüberstellung der Datenbanken, wird die Tabelle 4.1 herangezogen. Sie enthält vergleichbare Eigenschaften von Datenbanken, auf die im folgenden eingegangen wird.

Die erste Eigenschaft, ist das Erscheinungsjahr. Der Grund für die Aufnahme ist das Datenbanken die länger auf dem Markt sind, meist eine höhere Reife aufweisen können. Bewährte Datenbanken haben bereits viele Ihrer anfänglichen Probleme behoben, was den Umgang mit Ihnen erleichtert. Natürlich sind ältere Systeme nicht frei von Fehlern, jedoch existieren für diese viele Workarounds oder andere Lösungsansätze. Cassandra zum Beispiel, erhielt über die Jahre neben zahlreichen Bugfixes, CQL als Query Sprache, MapReduce Support, sekundäre Indizes, verbesserte Komprimierung und vieles mehr. Allerdings gibt es keine feste Regel, die besagt wann ein System, die Reife für den produktiven Einsatz erreicht hat. Es spielen natürlich auch andere Faktoren bei der Bestimmung der Ausgereiftheit eine Rolle, wie z.B. die Größe des Unternehmens oder Teams das hinter der Datenbank steht. Die Eigenschaft hat weniger den Zweck eines Kriteriums sondern eher eines Indikators.

Eine wichtige Rolle spielt jedoch die Lizenz, unter die Datenbank vertrieben wird. Für Unternehmen ist die Wirtschaftlichkeit eines Systems von großer Bedeutung. Deshalb bieten Open Source Produkte mit ihren geringen Anschaffungskosten, trotz des eingeschränkteren Supports, einen hohen Anreiz. Neben Wirtschaftlichkeit, ist Anpassbarkeit von Source Code, ein Argument für Open Source Produkte. Kommerzielle Lizenzen bieten hingegen eine

höhere Zukunftssicherheit als Open Source Produkte. Sollten die Entwickler der Open Source Produkte keine Lust oder Zeit mehr haben, kann die Entwicklung jederzeit eingestellt werden.

Unterstützte Programmiersprachen und Betriebssysteme sind Eigenschaften, bei denen eine Betrachtung des Ist-Zustandes sinnvoll ist. Im Unternehmen sollte idealerweise schon Erfahrung in den betrachteten Technologien vorhanden sein. Externe Mitarbeiter, sowie Schulungen sind teuer und müssen bei der Wahl, einer für das Unternehmen unbekannte Technologie, berücksichtigt werden.

Die Frage nach ein Schema stellt sich bei einer Betrachtung der Datenstruktur. Wenn sich die Struktur der abzulegenden Daten häufig ändert oder keine einheitliche Struktur unter den Daten zu erkennen ist, sind Schema freie Datenbanken von Vorteil. Den sie bietet ein hohes Maß an Flexibilität. Wohingegen man durch die Nutzung eines Schemas, eine bessere Kontrolle über die Daten besitzt.

Tabelle 4.1: Gegenüberstellung von den Charakteristika der Datenbanken

Eigenschaft	HBase	Cassandra	CouchDB	MongoDB	Redis	Voldemort	VoltDB	H2
Release-Datum	2008	2008	2005	2009	2009	2009	2010	2004
Datenbankmodell	Wide Column	Wide Column	Document	Document	Key-Value	Key-Value	Relational DBMS	Relational DBMS
Lizenz	Open Source	Open Source	Open Source	Open Source	Open Source	Open Source	Kommerziell	Open Source
Server-Betriebs-systeme	Linux, Unix, Windows	BSD, Linux, OS X, Windows	Android, BSD, Linux, OS X, Solaris, Windows	Linux, OS X, Solaris, Windows	BSD, Linux, OS X, Windows	Linux, Unix, Windows	Linux, OS X	plattformunabhängig
Daten-schema	schemafrei	schemafrei	schemafrei	schemafrei	schemafrei	schemafrei	ja	ja
Typisierung	nein	ja	nein	ja	nein	nein	ja	ja
Sekundärindizes	nein	eingeschränkt	ja (über Views)	ja	nein	nein	ja	ja
SQL	nein	nein	nein	nein	nein	nein	ja	ja
APIs und andere Zugriffs-konzepte	Java API, RESTful HTTP API, Thrift	Proprietäres Protokoll (CQL)	RESTful HTTP/JSON API	Proprietäres Protokoll basierend auf JSON	Proprietäres Protokoll	Proprietäres Protokoll	Java API, RESTful HTTP/JSON API, JDBC	Java API, ODBC, JDBC
Unterstützte Programmiersprachen	C, C#, C++, Groovy, Java, PHP, Python, Scala	C#, C++, Java, Perl, PHP, Python, Ruby, +5	C, C#, Java, JavaScript, Perl, PHP, PL/SQL, Python, Ruby, +9	C#, C++, Java, JavaScript, Perl, PHP, Python, Ruby, +4	C#, C++, Java, Perl, PHP, Python, Ruby, +12	C#, C++, Java, Perl, PHP, Python, Ruby, +8	C#, C++, Java, PHP, Python	C#, C++, Java, PHP, Python
MapReduce	ja	ja	ja	ja	nein	nein	nein	nein
Konsistenzkonzept	Immediate Consistency	Eventual Consistency, Immediate Consistency	Eventual Consistency	Eventual Consistency, Immediate Consistency	Eventual Consistency	Strict Consistency, Eventual Consistency	Integritätsbedingungen	Integritätsbedingungen
Transaktionskonzept	nein	nein	nein	nein	optimistisches Locking	nein	ACID	ACID
Nebenläufigkeit	ja	ja	ja	ja	ja	ja	ja	ja
Embeddable	nein	ja	ja	nein	nein	ja	ja	ja
In Memory fähig	nein	nein	nein	nein	ja	hybrid	ja	ja

Sekundärindizes können Lesegeschwindigkeiten steigern, weshalb sie eine interessante Datenbankenfunktion darstellen. Sie erlauben Indizes auf einem oder mehreren Schlüsseln

oder Nicht-Schlüsselattributen, was die Effizienz einer Suche steigern kann. Einige NoSQL Datenbank unterstützen solche Indizes, wohingegen relationale Datenbanksysteme die Definition beliebiger Sekundärindizes erlauben.

Typisierungen soll zum Ausdruck bringen, ob vordefinierte Datentypen wie Float oder Date in der Datenbank vorhanden sind. Ein Vorteil in der Verwendung von Datentypen ist eine Vorabkontrolle der Daten, sodass nur Daten mit den entsprechenden Eigenschaften verwendet werden. Zum Nachteil kann die mangelnde Flexibilität ausgelegt werden. Der Nutzer muss wie beim Schema, zwischen Flexibilität und Kontrolle entscheiden.

Die in der Datenbank verwendet Schnittstelle zur Client-Server Kommunikation, spielt bei der Architektur des gesamten Systems eine Rolle. Wird der Applikationsserver z.B. auf dem gleichen Server betrieben wie die Datenbank, ist eine Schnittstelle die nur über das Netzwerk angesprochen werden kann, nicht sehr sinnvoll. Wird die Datenbank hingegen über das Netzwerk von eventuell mehreren Servern angesprochen, so eignet sich der Einsatz von REST-Protokollen.

Die Entscheidung ob eine gewisse Stärke der Konsistenz ausreichend ist, wird durch den Anwendungsfall bestimmt. In manchen Anwendungen ist es schlichtweg egal, ob Daten redundant sind oder nicht. Die nächst höchste Anwendungsschicht, muss bei Inkonsistenz damit rechnen, sonst kann es zu schwerwiegenden Fehlern kommen. Beim Transaktionskonzept verhält es sich wie bei der Konsistenz, es hängt vom Anwendungsfall ab. Nebenläufigkeit gibt lediglich an, ob gleichzeitig ausgeführte Datenmanipulation, durch die Datenbank unterstützt wird.

Ob eine Datenbank im Embedded Modus betrieben werden kann ist von Bedeutung, wenn eine Integration in die Anwendung gewünscht ist. Dadurch können z.B. Verzögerungen durch Netzwerkzugriffe bei der Datenabfrage vermieden werden.

Die Eigenschaft In Memory spiegelt den Wunsch der CAS Software AG wieder. Sie stellt somit, ein sehr wichtigstes Kriterium für die Auswahl der Datenbank dar.

4.3 Auswahl einer Datenbank

Jede Datenbank hat seine eigenen Stärken und Schwächen. Bei der Wahl der passenden Datenbank, ist nicht entscheiden, welche Datenbank im Vergleich zur anderen die Beste ist. Vielmehr ist von Bedeutung, ob die entsprechende Datenbank, den Anforderungen an das Gesamtsystem gerecht wird.

Dementsprechend ist in diesem Anwendungsfall die Abfragegeschwindigkeit einer Datenbank am bedeutsamsten. Die Verwendung des Hauptspeichers als Primärspeicher bedeutet einen theoretischen Geschwindigkeitsvorteil, um den Faktor 100.000. In der Realität allerdings, spielen bei der Abfragegeschwindigkeit viele verschiedene Faktoren eine Rolle. Trotzdem dürfte der Geschwindigkeitsvorteil enorm gegenüber traditionellen Systemen sein. Fünf der Neun Datenbanken bieten diese Möglichkeit nicht. Deswegen ist zu klären ob diese Datenbanken andere Charakteristiken aufweisen können, um diesen Nachteil auszugleichen.

Cassandra und HBase ermöglichen hohe Performance durch horizontale Skalierung. Horizontale Skalierung ist vor allem bei hoher Last sinnvoll. Die Kunden der CAS Software AG sind alles mittelständische Unternehmen, welche nicht an die Nutzerzahlen von Facebook und Google herankommen. Daher sind keine Zugriffe im Millionen Bereich zu erwarten. Horizontale Skalierung ist dementsprechend nicht notwendig, sowie durch die Limitierung auf einen Rechner nicht möglich. Es ist zu erwarten das Cassandra und HBase auf einzelnen Servern nicht an die Performance von In Memory fähigen Datenbanken herankommen. Dies führte zu einer Entscheidung gegen die beiden Vertreter der Wide Column Stores.

Die Document Datenbanken sind zwar auch horizontal skalierbar, kommen jedoch nicht an die Performance von beiden zuvor genannten Datenbanken heran. Ihre Stärke liegt in Ihrer Schema freien Datenhaltung, die an dieser Stelle von geringem Wert ist, da die Daten eine feste Struktur haben. Außerdem werden Funktion wie SUM nicht in der Datenbank eigenen API mitgeliefert, was sie für analytische Aufgaben bedingt brauchbar macht. Letztendlich können CouchDB und MongoDB keine Argumente liefern, weshalb sie schneller sein sollten, als Hauptspeicher basierte Datenbanken.

Die Key-Value-Stores ermöglichen mit Ihrer Form der Datenhaltung und der In Memory Fähigkeit, hohe Zugriffsgeschwindigkeiten. Was Ihnen jedoch zum Nachteil ausgelegt werden kann, ist ihre mangelnde Komplexität. Weiterhin sind sie auf Punkt-Abfragen ausgelegt. Komplexe Anfragen sind nur durch eine Realisierung in der Logikschicht möglich. Welche eine enormen Steigerung des Aufwands bedeutet. Daher entschied man sich auch gegen die Key-Value-Stores.

VoltDB ist von den Eigenschaften her ein optimaler Kandidat, allerdings nicht Open Source. Die Datenbank konnte dadurch nicht verwendet werden. H2 hingegen ist Open Source und bietet Optionen zum vorhalten der Tabellen im Hauptspeicher. Davon erhofft man sich hohe Geschwindigkeitsvorteile gegenüber herkömmlichen relationalen Systemen. Durch den Ansatz der relationalen Algebra, ist das Arbeiten mit SQL möglich. Das birgt Vorteile, da auf bereits bekanntem Wissen aufgebaut werden kann.

5. Konzeption

Ein Konzept dient in der Softwarearchitektur der groben Strukturierung eines Softwaresystems. Zur Gestaltung werden neben funktionalen und nicht funktionalen Anforderungen, technische und organisatorische Einflussfaktoren hinzugezogen. Für erste Überlegung werden alle Komponenten, die zur Realisierung benötigt werden, in Verbindung zueinander gesetzt. Weiterhin sind Technologien festzulegen, die zur Umsetzung von bestimmten Komponenten verwendet werden können. Anschließend werden die Entwürfe, der einzelnen Komponenten im Detail erstellt.

5.1 Architektur

Zuerst wird ein erster Überblick über den groben Aufbau des Systems gegeben. In Abbildung 5.1 können die Zusammenhänge des abzubildenden Software-Systems betrachtet werden. Bei einer Betrachtung in der 3-Schichten-Architektur stellt der Browser und die Client.war die Darstellungsschicht dar. Die Fachkonzeptschicht ist in der Server.war umgesetzt. Die Datenbank befindet sich zwar auch in der Server.war, allerdings ist Sie trotzdem unabhängig und kann jederzeit separat betrieben werden.

Die Vaadin Client-Side Engine verwaltet das Rendering der Oberfläche im Web-Browser, durch den Einsatz verschiedener Client-Seitiger Widgets, die das Gegenstücke zu den serverseitigen Komponenten bilden. Es leitet Benutzerinteraktionen an die Server-Seite weiter und rendert anschließend die Änderungen für die Benutzeroberfläche. Die Kommunikation findet über asynchrone HTTP-oder HTTPS-Anfragen statt.

Server seitig arbeitet die Vaadin-Anwendungen auf der Java-Servlet-API. Das Vaadin Servlet oder genauer die VaadinServlet Klasse ist für die Delegation verschiedenen Clients zuständig. Sie empfängt Anfragen und legt mithilfe von Cookies fest, welche Benutzersitzung zu welchem Client gehört.

Interaktion mit dem Benutzer-Interface-Komponenten erzeugen Events, die zunächst auf der Client-Seite durch Widgets verarbeitet werden. Nachfolgend werden die Events durch den HTTP-Server, das Vaadin Servlet und durch die Komponenten der Benutzeroberfläche geleitet, bis Sie zu den in der Anwendung definierten Event-Listenern gelangen. In den Listenern wird mithilfe des REST-Clients ein POST-Requests an die Logik gesendet. Dieser enthält alle in der Oberfläche definierten Parameter.

In der Server.war werden REST-Requests entgegen genommen. Anhand der mitübertragenen Filteroptionen, werden die Bedingungen für die Datenbank Abfrage zusammengestellt.

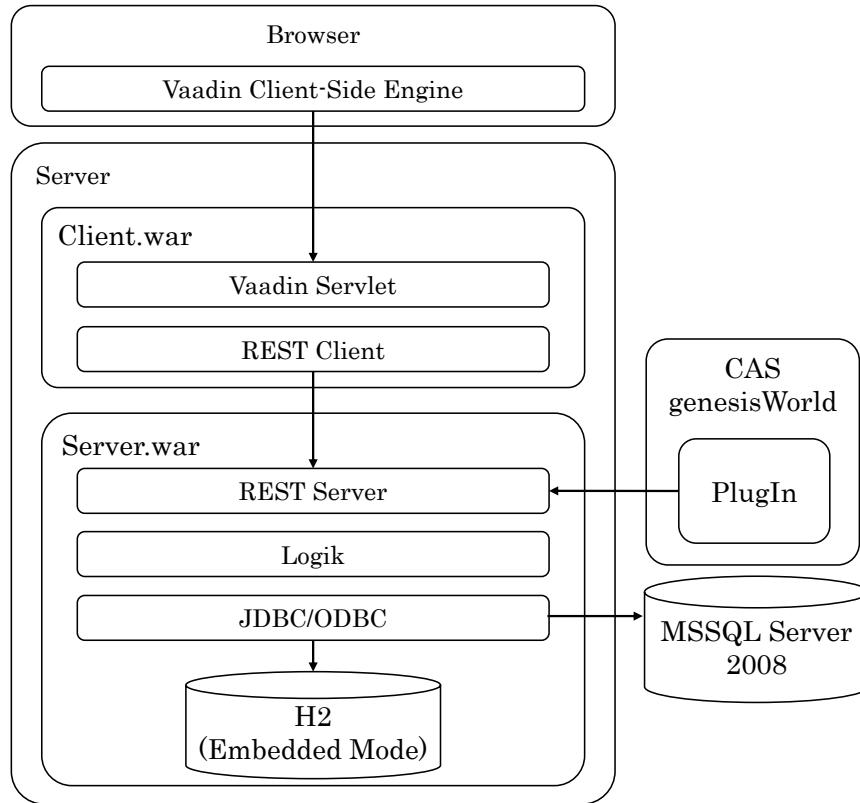


Abbildung 5.1: Architektur des Systems

Anschließend wird eine Verbindung zur H2-Datenbank aufgebaut. Das Ergebnis der Abfrage wird in das JSON-Format überführt und zurück an die Client.war geschickt. Dort angekommen werden die Daten an die Chart-Komponenten übergeben, was ein Neuaufbau der Komponente bewirkt.

Eine der Anforderung ist die unabhängige Umsetzung von Client und Server. Der erste Schritt zur Umsetzung, der geforderten losen Kopplung zwischen Darstellung und Logik, wird durch die Aufsplittung in zwei verschiedene Anwendungen erreicht. Die Client.war beinhaltet die Klassen und Objekte der Darstellung. Wohingegen die Server.war alle Elemente zur Umsetzung der Logik beinhaltet. Die Verwendung des REST-Protokolls zwischen der Client.war und Server.war stellt den nächsten Schritt der losen Kopplung dar. Einer der Vorteile ist, dass Funktionen des Systems durch andere Clients abgegriffen werden können, ohne Änderungen am Server durchführen zu müssen. Beide WAR-Dateien werden in einem Apache Tomcat Webserver deployed und können über URLs angesprochen werden.

Die Logikkomponente in der Architektur stellt eine Zusammenfassung aller Funktionen des Anwendungskerns dar. Sie kümmert sich um die Generierung der Abfragen an die Datenbank. Welche eine dynamisch Generierung der Abfragen vornimmt, um durch keine unnötigen Bedingungen, die Abfragegeschwindigkeit zu verringern. Abfragen werden mit Hilfe der Java Database Connectivity(JDBC) an die Datenbank gestellt. Neben der Generierung der Abfragen, enthält die Logikkomponente Funktionen zum Extrahieren und Transformieren der Daten aus der alten Datenbank. Der ETL-Prozess wird nur einmalig ausgeführt, allerdings stellt er einen der wichtigsten Schritte für die Umsetzung dar.

Um nicht periodisch Extraktion und Transformation wiederholen zu müssen, wird ein selbstgeschriebenes PlugIn im CAS genesisWorld Anwendungsserver eingesetzt. Die Grundidee des PlugIns, ist Benachrichtigungen über Änderungen an unser System zu über-

mitteln. Dort wird Kontrolliert, ob der Datensatz eine Relevanz besitzt. Ist dies der Fall, besorgt sich die Anwendungslogik, anhand der zuvor übermittelten GGUID, alle benötigten Daten.

5.2 Technologien

Als einer der am meist verbreitetsten Programmiersprachen, stellt Java die Grundlage aller verwendeten Technologien dar. Zur Darstellung der Inhalte für den Client wird Vaadin verwendet. Der Apache Tomcat7 nimmt die Rolle des Anwendungsservers ein. Die Kommunikation auf Basis von RESTful Web Services wird mithilfe von Jersey realisiert. OpenSCV wird für das Lesen und Schreiben von CSV-Dateien verwendet. JDBC dient der Kommunikation zwischen Anwendungsserver und der Datenbank. Die H2-Datenbank stellt die Datenquelle des Systems dar. Im folgenden werden alle Bestandteile bis auf den H2 der bereits erläutert wurde, näher beschrieben.

Vaadin Vaadin ist ein Open-Source-Java-basiertes Framework für den Aufbau von modernen Web-Anwendungen. Der Kerngedanke des Frameworks ist, dass alle Anwendungslogik in der Server-Seite ausgeführt wird, während die Client-Seite nur für das Senden der Benutzeraktionen an den Server und die Reaktion auf den Antworten, die er empfängt, verantwortlich ist. Da es auf GWT basiert, können sowohl die Client- und die Server-Code in reinem Java geschrieben werden.

Die aktuelle Version Vaadin , wurde im Februar 2013 veröffentlicht. Der bekannteste Wechsel von Vaadin 6, war die Integration von GWT zu Vaadin, die eine bessere Unterstützung für die clientseitige Widget Entwicklung bedeutete und sogar die Möglichkeit zu Erstellung von offline Vaadin-Anwendungen mit sich bringt.

Neben Open-Source, ist die im Unternehmen vorhandene Erfahrung, ein Grund für die Wahl des Frameworks. Ausschlaggebend war jedoch VaadinCharts, welches ein Erweiterung von Vaadin darstellt. Es basiert auf Highcharts, einem JavaScript-Packet, welches eine umfangreiche Sammlung an Funktionen zur Darstellung von Diagrammen besitzt.

Jersey Jersey RESTful Web Services ist ein Open-Source-Framework zur Entwicklung von RESTful Web Services in Java, die Unterstützung für JAX-RS-APIs bietet und die JAX-RS (JSR 311 und JSR 339)-Referenzimplementierung darstellt. JAX-RS-Annotationen werden verwendet, um die REST Relevanz von Java-Klassen zu definieren. Jersey ist die Referenzimplementierung, der Spezifikation. Jersey enthält im Grunde einen REST-Server und einen REST-Client. Auf der Serverseite verwendet Jersey ein Servlet, die vordefinierten Klassen abtastet, um REST-Ressourcen zu identifizieren. Über die web.xml Konfigurationsdatei werden die von der Jersey-Distribution bereitgestellten Servlets registriert. Dieses Servlets analysieren die eingehenden HTTP-Anforderung und wählt die richtige Klasse und Methode für diese Anfrage aus. Diese Auswahl basiert auf Annotationen, in den Klassen und Methoden. Weiterhin unterstützt JAX-RS die Erstellung von XML-und JSON, über die Java Architektur für XML Binding (JAXB).

Apache Tomcat Tomcat ist ein Open-Source-Web-Server entwickelt von der Apache Group. Apache Tomcat implementiert die Java Servlet und der Javaserver Pages (JSP) Spezifikationen von Sun Microsystems und ist daher eine Referenzimplementierung. Er stellt weiterhin eine rein auf Java basierte HTTP Web Server Umgebung dar. Apache Tomcat enthält Tools für Konfiguration und Management, kann aber auch durch die Bearbeitung von XML-Dateien konfiguriert werden.

Opencsv Da Java das Parsen von CSV-Dateien nativ nicht unterstützt, müssen wir auf Drittanbieter-Bibliothek zurückgreifen. Opencsv ist eine sehr einfache CSV-Parser-Bibliothek für Java. Die Bibliothek kann zum erstellen, lesen und schreiben von CSV-Dateien benutzt werden. Die beste Fähigkeit des OpenCSV Parsers ist das Mapping von Ergebnissen auf Java-Bean-Objekte.

JDBC Die JDBC-API ermöglicht den programmgesteuerten Zugriff auf relationale Daten, aus der Java Programmiersprache heraus. Durch Verwendung der JDBC-API können Anwendungen SQL-Anweisungen ausführen, Ergebnisse abrufen und die Veränderungen auf die Datenquelle zurückschreiben. Der JDBC-API kann auch mit mehreren Datenquellen in einer verteilten, heterogenen Umgebung interagieren.

5.3 Datenbankdesign

Das Datenbankdesign stellt einen der wichtigsten Abschnitte der Konzeption dar. Festlegungen im Bereich des Datenmodells werden in dieser Phase getroffen. Sie entscheiden ob Anforderungen und Erwartungen erfüllt werden können. In dieser Phase sind die Charakteristika der Daten zu untersuchen und das Datenmodell entsprechend nach Ihnen auszulegen.

5.3.1 Konzeptionelles Design

Normalisierung dient der Organisation von Feldern und Tabellen einer relationalen Datenbank, um Redundanz und Abhängigkeit zu minimieren. Die Kehrseite hingegen ist eine Steigerung des Aufwands, um die benötigten Daten wiederzugewinnen. Normalisierung bietet die Möglichkeit einen Austausch zwischen Performance und Stabilität des Datenbankmodells vorzunehmen. In unserem Fall stellt ersteres absolute Priorität dar. Daher wird versucht, die Normalisierung so gering wie möglich zu halten.

Die erste Überlegung hinsichtlich des Schemas ist, welche Daten für die Beantwortung der Abfragen benötigt werden. Der Datenbankdesigner steht bei analytischen System immer vor der Entscheidung, wie viele Information aus dem alten System in das Neue übernommen werden sollten. Um höchst mögliche Performance zu erreichen werden lediglich die für das Szenario benötigten Daten extrahiert. Allerdings entsteht durch nachträgliche Hinzunahme von Funktionen ein erhöhter Aufwand für Änderungen am Schema und des ETL-Prozesses. Abbildung 5.2 zeigt das für die Datenbank neu entworfene Schema.

Die Idee hinter dem Schema ist, die Verwendung einer einzelnen Tabelle zur Aufbewahrung der Informationen, über die Verbindungen. Diese Tabelle ermöglicht es, ausgehend von einem Benutzer, alle Verbindungen zu anderen Personen zu finden. Im Grunde genommen sind vier Spalten dafür ausreichend. Die erste Spalte startID beinhaltet die Person, von der die Suche ausgeht. Eine Zuordnung der Tupel zu einem Datum erfolgt über die Spalte Date. Um eine Unterscheidung zwischen den Verbindungen zu erhalten, wird der Typ in der Spalte DataTyp vermerkt. Die letzte Spalte endID beinhaltet die Personen zu denen die Verbindung letztendlich führt. Anderen Spalten wie z.B. Town oder Country dienen lediglich der Filterung der Ergebnisse.

Um mit den geringeren Speicherkapazitäten die uns zur Verfügung stehen zurechtzukommen, wird auf das Problem der Datenredundanz eingegangen. Durch Normalisierung lässt sich Datenredundanz zwar nicht verringern, allerdings kann man sie in kontrollierbare Bahnen lenken. Im neuen Schema wurden solche Maßnahmen auf die Spalte Town und Country angewendet. Beide Spalten werden voraussichtlich Millionen von Werten beinhalten. Es gibt jedoch nur 193 Länder auf der Welt. Das bedeutet das Wörter, wie Deutschland sich

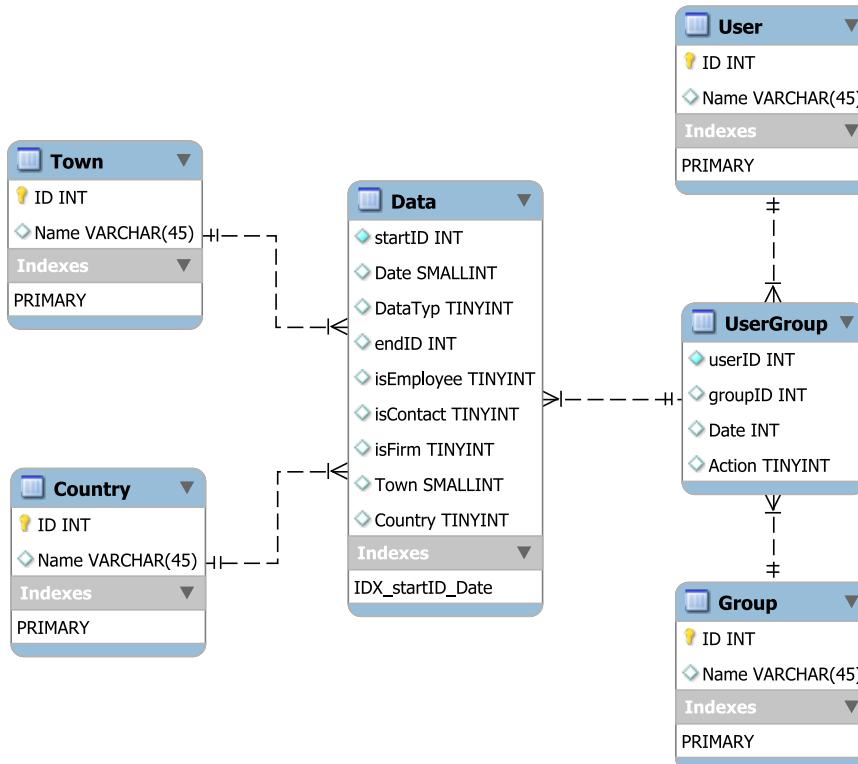


Abbildung 5.2: Neue Datenbankschema

sehr oft wiederholen. Die Spalte Country ist vom Datentyp Varchar, welches pro Zeichen 2 Byte benötigt. Das wären beim Wort Deutschland 22 Byte. Legt man nun für die Spalte Country eine neue Tabelle an, wird in dieser jedes Land nur einmal vermerkt. Jedes Land bekommt einen Schlüssel in Form einer Zahl. In der eigentlichen Tabelle Data werden nur noch die Zahlen, anstatt des vollständig ausgeschrieben Wortes, verwendet. Das würde beispielsweise mit dem Wort Deutschland eine Reduktion von 22 Byte auf 1 Byte bewirken. Die Reduzierung auf 1 Byte lassen sich auf das TINYINT Format zurückführen. Das gleiche gilt für die Spalte Town. Bei ihr wird allerdings der Datentyp SMALLINT verwendet, mithilfe dessen ein Zahlenbereich von -32768 bis 32767 abgebildet werden kann. Die Spalten isEmployee, isContact und isFirm können nur zwei verschiedene Zustände darstellen. Stimmt oder stimmt nicht. Der Datentyp TINYINT reicht daher zur Abbildung des Zustandes völlig aus. Ein Feld vom Typ datetime benötigt 8 byte an Speicher. Um hier ebenfalls Einsparungen vorzunehmen, wurde beschlossen das Datum als SMALLINT zu deklarieren. Dies ist möglich da nur das Tages-Format des Datums von Interesse ist. Dazu wird ein frei gewählter Nullpunkt festgelegt. In unserem Fall wurde der 01.01.1990 als Nullpunkt gewählt, da keine älteren Daten existieren. Darauf aufbauend wird das Datum, durch die Differenz in Tagen zum Nullpunkt, in der Spalte Date abgelegt. Die Hochrechnung der Tabelle 5.1 zeigt das durch die Normalisierung der Speicherplatzverbrauch um den Faktor 6 gesenkt werden kann.

Möchte man nun die Abfrage eines Benutzers, die eine Filterung anhand einer Stadt voraussieht beantworten, muss man zuerst an die ID der Stadt herankommen. Dabei können zwei verschiedene Ansätze verfolgt werden. Der erste Ansatz wäre einen Join zwischen Town und Data, um direkt mit dem Namen der Stadt zu arbeiten. Diese Variante dürfte aufgrund des Kreuzproduktes von Millionen von Zeilen nicht sehr performant sein. Eine andere Möglichkeit ist, eine separate Abfrage an die Datenbank zu stellen, in der die ID zum Namen ermittelt wird. Mithilfe der ID kann dann ohne einen Join die Ergebnismenge

Speicherplatzverbrauch ohne Normalisierung

Zeitpunkt(timestamp)	8 byte	x	18.000.000	=	~137 MB
Stadt(varchar)	16 byte	x	18.000.000	=	~343 MB
Land(varchar)	20 byte	x	18.000.000	=	~274 MB
				Summe	~754 MB

Speicherplatzverbrauch mit Normalisierung

Zeitpunkt(smallint)	2 byte	x	18.000.000	=	~34 MB
Stadt(integer)	4 byte	x	18.000.000	=	~72 MB
Stadt(varchar)	16 byte	x	21.000	=	~0,32 MB
Land(tinyint)	1 byte	x	18.000.000	=	~17 MB
Land(varchar)	20 byte	x	218	=	~0,004 MB
				Summe	~123 MB

Tabelle 5.1: Vergleich des Speicherplatzverbrauchs

ermittelt werden. Dieser Ansatz dürfte vor allem durch die Abwesenheit von Netzwerkzugriffen zur besseren Performance führen. Dieses Vorgehen kann für die Stadt, das Land und die Gruppenzugehörigkeit angewendet werden.

Die Tabelle GroupDate unterscheidet sich von den anderen Auslagerungstabellen, den dort sind noch weitere Details vermerkt. Diese ermöglichen es die Zusammenstellung von Gruppen über die Zeit nachzuvollziehen. Action legt fest ob die Tupel einen Eintritt einer Person oder einen Austritt darstellt. Die Spalte Date beinhaltet das Datum, des Ereignisses. Mithilfe beider Attribute lassen sich Gruppenzusammenätzungen auf bestimmte Zeitpunkte bezogen rekonstruieren.

5.3.2 Zugriffsstrukturen

Indizes dienen der Beschleunigung von Suchen nach bestimmten Spaltenwerten. Ohne Indexe müsste die H2-Datenbank beim ersten Datensatz beginnen und dann die gesamte Tabelle durchgehen, um eine Abfrage zu beantworten. Je größer die Tabelle ist, desto höher sind die Kosten dafür. Daher bietet der Einsatz sich gerade in Anbetracht nach der Forderung von Performance an. Zu Beachten ist jedoch, dass jeder Index einen Zuwachs des Speicherplatzverbrauchs mit sich bringt. Zur Indexierung der Tabellen Town, Country, User und Group eignen sich Hash-Indizes. Sie bieten einen extrem schnellen Zugriff auf die Daten. Diese Schnelligkeit ergibt sich aus der Verwendung von Berechnungsvorschriften, zur Ermittlung der Position, des gesuchten Wertes. Indiziert werden in unserem Schema die Spalte Name in der jeweiligen Tabelle, da der Client nur die jeweiligen Namen besitzt. Mithilfe der Namen werden die zugehörigen IDs ermittelt. Die Nutzung von Hash-Indizes bringt allerdings Limitierungen mit sich. Eine der wichtigsten ist, dass Sie nur für Vergleiche(“=”) verwendet werden können. Somit werden keine Wertebereich-Abfragen(“<” oder “>”) unterstützt. Es gibt allerdings noch andere Nachteile [SSH11], auf die aber in dieser Arbeit nicht näher eingegangen wird. Für die Tabelle UserGroup eignet sich der Standard Index von H2, der ein B⁺-Baum verwendet. Dieser kann für die Spalte userID verwendet werden, der den ersten Wert einer Suche darstellt. Der B⁺-Baum eignet sich auch für die Data-Tabelle. Hier ist außerdem die Verwendung eines Mehr-Attribut-Indexes vorgesehen. Der Vorteil eines Mehr-Attribut-Indexes ist, dass bei einer Punkt-Abfrage über alle Zu-

griffsattributwerte nur ein Indexzugriff erfolgen muss. Indexiert werden in unserem Fall die Spalte startID und Date. Beide Spalten sind sortiert und bieten sich somit für die Verwendung eines geclusterten Index an. Geclusterte Indizes sind in der gleichen Form sortiert wie die interne Relation. Ein geclusterter Index unterstützt Bereichsanfragen sehr gut, was bei der Beschränkung auf Zeitspannen von Vorteil sein dürfte.

5.4 Extract Transform Load Prozess

Daten der operativen Systeme unterstützen die wertschöpfende Geschäftsprozesse innerhalb eines Unternehmens. Sie sind demnach auf die Steuerung und Überwachung des Tagsgeschäfts ausgerichtet und daher transaktionsbezogen. Somit sind die Daten in Ihren Begrifflichkeiten häufig nicht vergleichbar und ihrer Bewertung sowie Konsolidierung unterschiedlich. Um die Daten dennoch für analytische Zwecke einzusetzen, ist eine Überführung in eine geeigneter Struktur von Vorteil. Eine solche Überführung wird in der Literatur als Extract, Transform, Load (ETL)-Prozess bezeichnet [ESHB11].

5.4.1 Extract

Zunächst dient die Extraktion primär der Beschaffung von Daten aus dem MSSQL Server 2008. Überdies können durch den Prozess Daten bereits reduziert, zusammengeführt und ersetzt werden. Für eine zutreffende Formulierung der Abfragen, müssen Besonderheiten in die Ermittlung der Daten beachtet werden. Eine vollständige und korrekte Datenmenge stellt die Grundlage jeder guten Analyse dar.

Die erste Besonderheit stellt die Betrachtung in Bezug auf Zeitspannen dar. Bei Analysen über die Zeit ist zu beachten, dass Daten sich im Laufe der Zeit verändern und dies zu berücksichtigen ist. Die Tabelle Changelogbook bietet uns die Möglichkeit, Veränderungen in den Datensätzen nach zu vollziehen. Eine solche Veränderungen über die Zeit, ist in der Gruppenkonstellation zu finden, da Personen Gruppen verlassen oder beitreten können. Neben den Veränderungen über die Zeit sind Datensätze, die über mehrere Tage gehen, gesondert zu behandeln. Termine wie Tagungen und der gleichen erstrecken sich beispielsweise über mehrere Tage. In der MSSQL Datenbank werden diese Termine als ein Datensatz beachtet. In unserer Analyse stellt jede Tupel eine Verbindung dar. Jede Tupel besitzt einen Tag der für die Analyse herangezogen wird. Somit muss ein Datensatz, der sich über mehrere Tage erstreckt, in der H2-Datenbank in mehrere Teile aufgeteilt werden. Deswegen sollte im Ergebnis der SQL-Query vermerkt werden, dass dieser Termin mehrere Tage ging, damit dies in der Transformation berücksichtigt werden kann.

Eine weitere Besonderheit ergibt sich, durch ein nicht im System vorgesehenes Verhalten der Benutzer, welche die Auswertung der Daten erschwert. CAS genesisWorld ermöglicht es Termine zu schieben. Diese Funktion wird von manchen Nutzern missbraucht. Anstatt für einen ähnlichen Termin einen neuen Eintrag anzulegen, wird ein alter aus Bequemlichkeit geschoben. Das hat zur Folge, dass Termine die tatsächlich statt gefunden haben, in der Datenbank nicht mehr existieren. Um trotzdem diese Termine zu berücksichtigen wurde folgendes Konzept erarbeitet. Dem Changelogbook lässt sich entnehmen, ob die Feld start_dt und end_dt verändert wurden. Zur Feststellung ob ein Termin stattgefunden hat und anschließend geschoben wurde, müssen zwei Bedienungen erfüllt sein. Die erste ist, dass der Termin nach dem angegeben Zeitpunkt geschoben wurde. Werden Termine aus Gründen wie auch immer geschoben, findet dies in der Regel vor dem Start des Termimes statt, damit die Personen nicht unnötig zu dem Termin auftauchen. Die zweite ist, dass der neue Termin in der Zukunft liegt. Neben den beiden Bedingungen ist zu beachten, dass die Operation die auf die Datensätze ausgeführt wurde, eine Update war.

Zur Zwischenspeicherung der Ergebnisse der Extraktion wird eine Ablage der in CSV-Dateien vorgenommen. Dieser Zwischenschritt dient der Nachvollziehbarkeit zwischen der

Beschaffung der Daten und deren Transformation. Bei der Fehlersuche beispielsweise kann dies sehr hilfreich sein.

5.4.2 Transform

Zu Beginn der Transformation werden Filterungen durchgeführt. Unter der Filterung von operativen Daten, versteht man eine Bereinigung syntaktischer oder inhaltlicher Defekte, der zu übernehmenden Daten. Die MSSQL Datenbank besteht zu 37% aus Null Werten und zu 4% aus Leeren Feldern. Daten die beispielsweise Null-Werte enthalten und für die Ermittlung des Datums benötigt werden, sind für die Analyse nicht zu gebrauchen. Sie können daher im Laufe des Prozesses aus den Daten entfernt werden. Bei den anderen Filteroperationen können Nullwerte jedoch vernachlässigt werden, da sie Zweckessig abdingbar sind.

Der nächste Schritt wäre die Harmonisierung der Daten. Unter anderem besitzen die Telefonnummern kein einheitliches Format. Sie wurde manuell von Sachbearbeitern einge tragen. Das erfordert ein Zusammenführen aller Nummern in ein einheitliches Format, welches einen automatischen Vergleich ermöglicht. Verbindungen in Form von E-Mails, Terminen usw. müssen auch in eine einheitliche Form gebracht werden. Spalten die gleiche Inhalte besitzen aber unterschiedlich bezeichnet sind, müssen unter einem Terminus zusammengeführt werden.

Die in der Extraktion genannten Besonderheiten werden durch unterschiedliche Query-Abfragen ermittelt. Das führt zu vielen separaten Dateien. Diese sind zum Abschluss der Transformation zusammen zu führen. Das Ergebnis wird anschließend in einer CSV-Datei abgelegt, welche die Basis für das Befüllen der H2-Datenbank bildet.

5.4.3 Load

Beim Laden der Datensätze in den H2 kommt ein sogenannter ”bulk load” zum Einsatz. Dieser wird häufig zum laden von großen Datenmengen aus einer Datei in eine Datenbank eingesetzt. Er ermöglicht ein wesentlich schnelleres Befüllen der Datenbank bei großen Datenmengen, im Gegensatz zu den INSERT-Operationen.

5.5 Synchronisation des Datenbestandes

Systeme die auf den Datenbestand anderer Systeme aufbauen, können zwei verschiedenen Ansätze zur Sicherstellung ihrer Aktualität verfolgen. Unser nebenläufiges System bezeichnen wir als A und das System das den original Datenbestand beinhaltet als B. Einer der Ansätze ist die Intervall basierende Nachfrage über Veränderungen von A. Hierbei fragt A bei B in festgelegten Intervallen nach, ob Daten verändert wurden. Die Wahl des Nachfrage-Intervalls stellt dabei eine der größten Schwierigkeiten dar. Ist der Intervall zu groß, sinkt die Aktualität des Datenbestandes. Ist er zu klein, entsteht bei B ein starke Belastung. Der andere Ansatz ist das B über Benachrichtigungen A informiert. Dadurch werden keine unnötigen Abläufe angestoßen, da nur im Falle von neuen Daten, Prozesse in Bewegung gesetzt werden. Zwar wird die Aktualität der Daten gewährleistet jedoch büßt A an Entscheidungsfreiheit ein. A kann nicht mehr selbst entscheiden wann aktualisiert werden soll. Der zweite Ansatz ist zwar effizienter jedoch nicht immer umsetzbar. Das kann technische oder unternehmenspolitische Gründe haben, die notwendige Veränderung am Legacy Systems ausschließen.

In CAS genesisWorld gibt es eine Möglichkeit den zweiten Ansatz umzusetzen. Die Idee dabei ist den Applikationsserver um ein sogenanntes Plugin zu erweitern, dass über Ver änderungen in den Datensätzen benachrichtigt wird. Realisiert wird ein solches Plugin

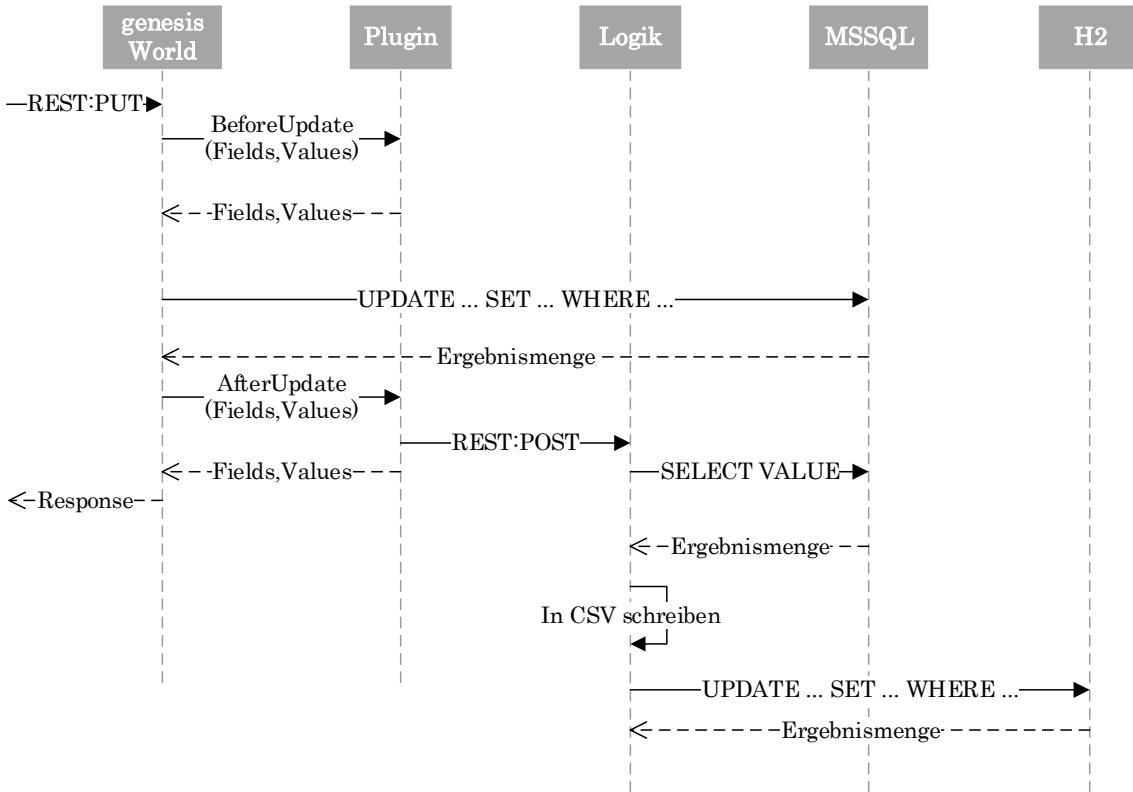


Abbildung 5.3: Sequenzdiagramm eines Updates

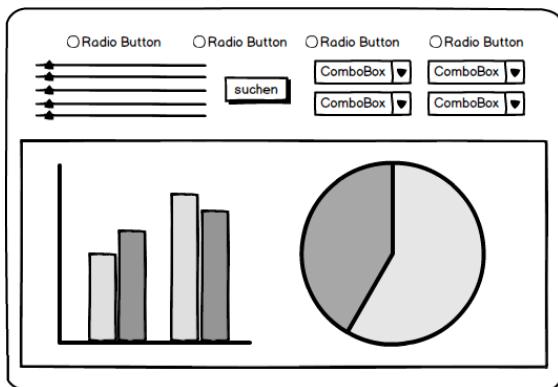
als COM-Objekt, welches das Interface IGWSDKDataPlugIn implementiert. Das erstellte COM-Objekt wird im Server von CAS genesisWorld registriert. Der Server delegiert, wie in Abbildung 5.3 zu sehen, bei einer Datenoperation, den Aufruf an die für den jeweiligen Datensatz-Typen registrierten PlugIns. Das Plugin selbst besitzt einen REST-Client, der einen POST an die Logik sendet. Sie enthält die GGUID des Veränderten Datensatzes. Mithilfe dessen die Extraktion des betroffenen Datensatzes durchgeführt wird. Der neue Datensatz wird zuerst in einer CSV-Datei zwischengespeichert und anschließend in die H2-Datenbank eingefügt. Bei Updates werden die Datensätze einfach aktualisiert.

5.6 Darstellungskonzepte

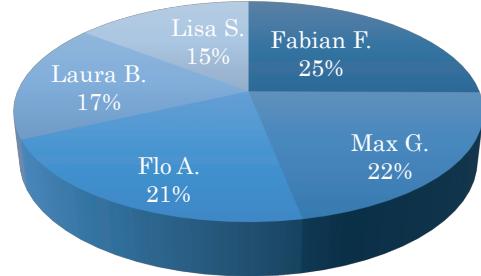
Bei der Konzeption einer Darstellung, ist die Grad der Granularität von Informationen ein wichtiger Leitfaktor zur Bestimmung des Aufbaus. In unserem Fall ist nicht die Eigenschaft einer Verbindung von interessier, sondern ihr Typ und ihre Häufigkeit zu einer bestimmten Person. Da keine Detailinformationen zur Verbindung vorhanden sind, kann jeder Benutzer frei wählen von welcher Person ausgehend, die Analyse stattfinden soll. Für die Oberfläche bedeutet dies einen Einstiegsplatz in Form eines Fensters, in dem der jeweilige Benutzername von dem die Suche ausgehen soll, eingegeben wird. Zusätzlich sollen die IP-Adresse und Portnummer des Server angebbar sein, falls dieser auf einem anderen Rechner läuft.

Nach dem Login findet eine Weiterleitung auf die eigentliche Seite statt. Dessen Aufbau ist in Abbildung 5.4 (a) zu sehen. Oben auf der Seite sind alle Regler, CheckBoxen und Eingabefelder zur Filterung der Ergebnismenge zu finden. Direkt darunter befindet sich das Diagramm das die Ergebnismenge einer Abfrage darstellt.

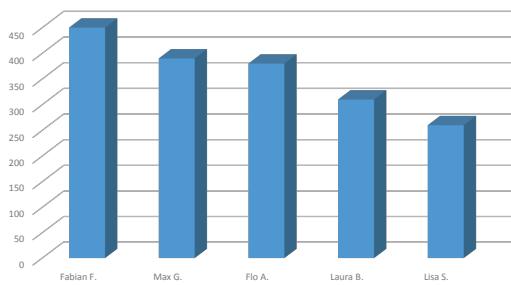
Diagrammtypen gibt es viele jedoch ergeben sich Einschränkungen durch das Framework, welches zu Realisierung verwendet wird. Im Prinzip lässt sich jede Darstellung verwirkli-



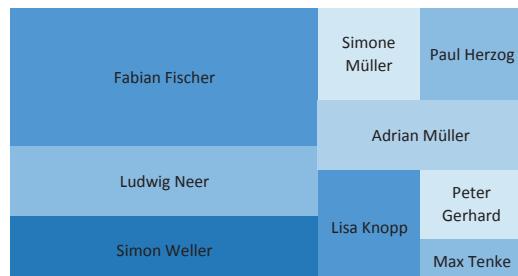
(a) Grober Entwurf des Aufbaus der Hauptseite



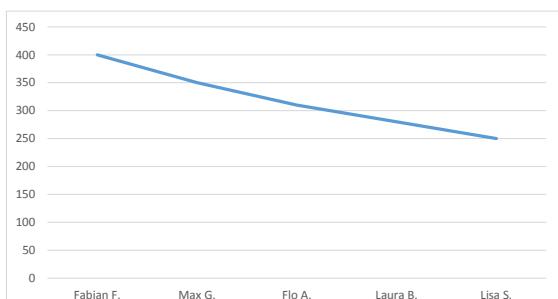
(b) Tortendiagramm



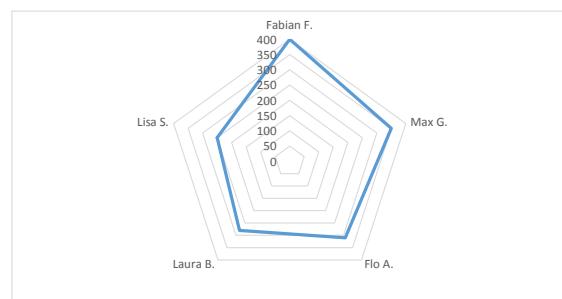
(c) Balkendiagramm



(d) Tree Map



(e) Liniendiagramm



(f) Netzdiagramm

Abbildung 5.4: Entwürfe der Oberfläche

chen, allerdings ist das Aufwand Nutzen Verhältnis zu berücksichtigen. In einer Vorauswahl wurden einige Typen ausgewählt die in Abbildung 5.4 (b)-(f) dargestellt sind.

Netzdiagramme geben Eigenschaften verschiedener Systeme wieder. Sie eignen sich daher gut zur Darstellung von Ausprägungen. Für unsere Form der Daten ist diese Darstellung gänzlich ungeeignet. Mithilfe von Liniendiagrammen lassen sich Trends und Zeitreihen darstellen. Die Verwendung verschiedener Linien ermöglicht zudem die Darstellung mehrerer Trends. Die Benutzung dieses Diagramms macht keinen Sinn, da die Ergebnismenge sich nicht auf verschiedene Zeitpunkte bezieht, sondern die Summe der Werte in der Zeitreihe beinhaltet. Eine Tree Map dient der Abbildung von hierarchischen Daten. Dabei steht jede Fläche eines Rechtecks im proportionalen Zusammenhang zur Gesamtfläche. Die Beachtung von Größenverhältnissen stellt einen nützlichen Eigenschaft für unsere Daten dar. Eine Hierarchie innerhalb der Daten ist nicht im klassischen Sinn vorhanden. Vielmehr würde jedes Rechteck aus dem jeweiligen Anteilen der Verbindungstypen bestehen. Beispielsweise könnte die Person Ludwig Neer wiederum in Rechtecke unterteilt werden, die die Anzahl der E-Mails, Termine usw. enthalten. Das würde allerdings schnell zu einer schlechten Übersicht führen, da viel zu viele Kacheln dargestellt werden müssen. Kreisdiagramme ermöglichen eine Betrachtung der Gesamtheit zu ihren Einzelstücken, da der Kreis ein geschlossenes System darstellt. Allerdings müssen alle Teile sich auf die gleiche Basis beziehen. Es eignet sich hervorragend zur Darstellung von Verhältnissen. Möchte man jedoch noch die Zusammenstellung eines einzelnen Stückes noch einmal aufteilen, ist eine zweite Ansicht nötig. Am besten dürfte sich ein Balkendiagramm eignen. Reihenfolgen beispielsweise lasse sich durch die resultierenden Stufen sehr gut darstellen. Balken selbst lassen sich außerdem in einzelne Teile aufspalten, ohne die Übersichtlichkeit zu verringern. Gegenüber dem Kreisdiagramm kann es zwar keine Betrachtung des Gesamten liefern, allerdings ist das in diesem Anwendungsfall auch nicht nötig.

6. Umsetzung

6.1 Aufbau der Server.war

Das Server Web Archive beinhaltet ein dynamisches Web Projekt aus dem Eclipse Web Tools Platform (WTP) Projekt. Das Project weist die typische Struktur eines Web Projektes auf. Daher wird im folgenden nur auf die Klassen eingegangen. Abbildung 6.1 zeigt das Klassendiagramm der Server.war. Das Diagramm dient als Basis für die nachfolgenden Erläuterungen.

Die H2-Datenbank wird im Embedded-Modus betrieben, was eine Instanziierung der Datenbank zur Laufzeit notwendig macht. Die Instanziierung erfolgt in der Klasse Database. Das Attribut dataSource stellt die H2-Datenbank in Form eines Objektes dar. Eine Verbindung zur Datenbank wird mithilfe der Methode .getConnection() aufgebaut. Diese Verbindung wird permanent offen gehalten solang der Tomcat Server läuft. Dazu wird die Verbindung dem Attribut con zugewiesen, die von allen Methoden verwendet wird die eine Verbindung zur Datenbank aufzubauen wollen. Um die Datenbank mit dem deployen der Web-Anwendungen zu starten, ist die Verwendung eines Servlets nötig. Dazu benutzen wir die Klasse EntryPoint die das Interface HttpServlet implementiert. Um das Servlet direkt beim Start aufzurufen wird in der web.xml folgende Zeilen eingetragen:

```
1 <servlet>
2   <servlet-name>H2</servlet-name>
3   <servlet-class>de.cas.db.EntryPoint</servlet-class>
4   <load-on-startup>1</load-on-startup>
5 </servlet>
```

Die 1 im Element <load-on-startup> bewirkt den Aufruf der Methode init() die eine Instanziierung der Klasse Database vornimmt. Zur Erzeugung des Schemas wird eine separate Klasse namens SchemaBuilder eingesetzt. In Ihr werden sämtliche SQL-Anweisungen zur Generierung des Schemas aufbewahrt und können über die Methode createSchema() ausgeführt werden.

Mit der Klasse JerseyServer wird der REST-Server umgesetzt. Sie besitzt Methoden die mit den entsprechenden Annotationen wie @GET oder @POST die REST-Requests entgegen nehmen. Mit der Annotation @Path wird die URL angegeben unter der die Methode angesprochen werden kann. Diese Methoden können Übergabeparameter vom Typ UriInfo

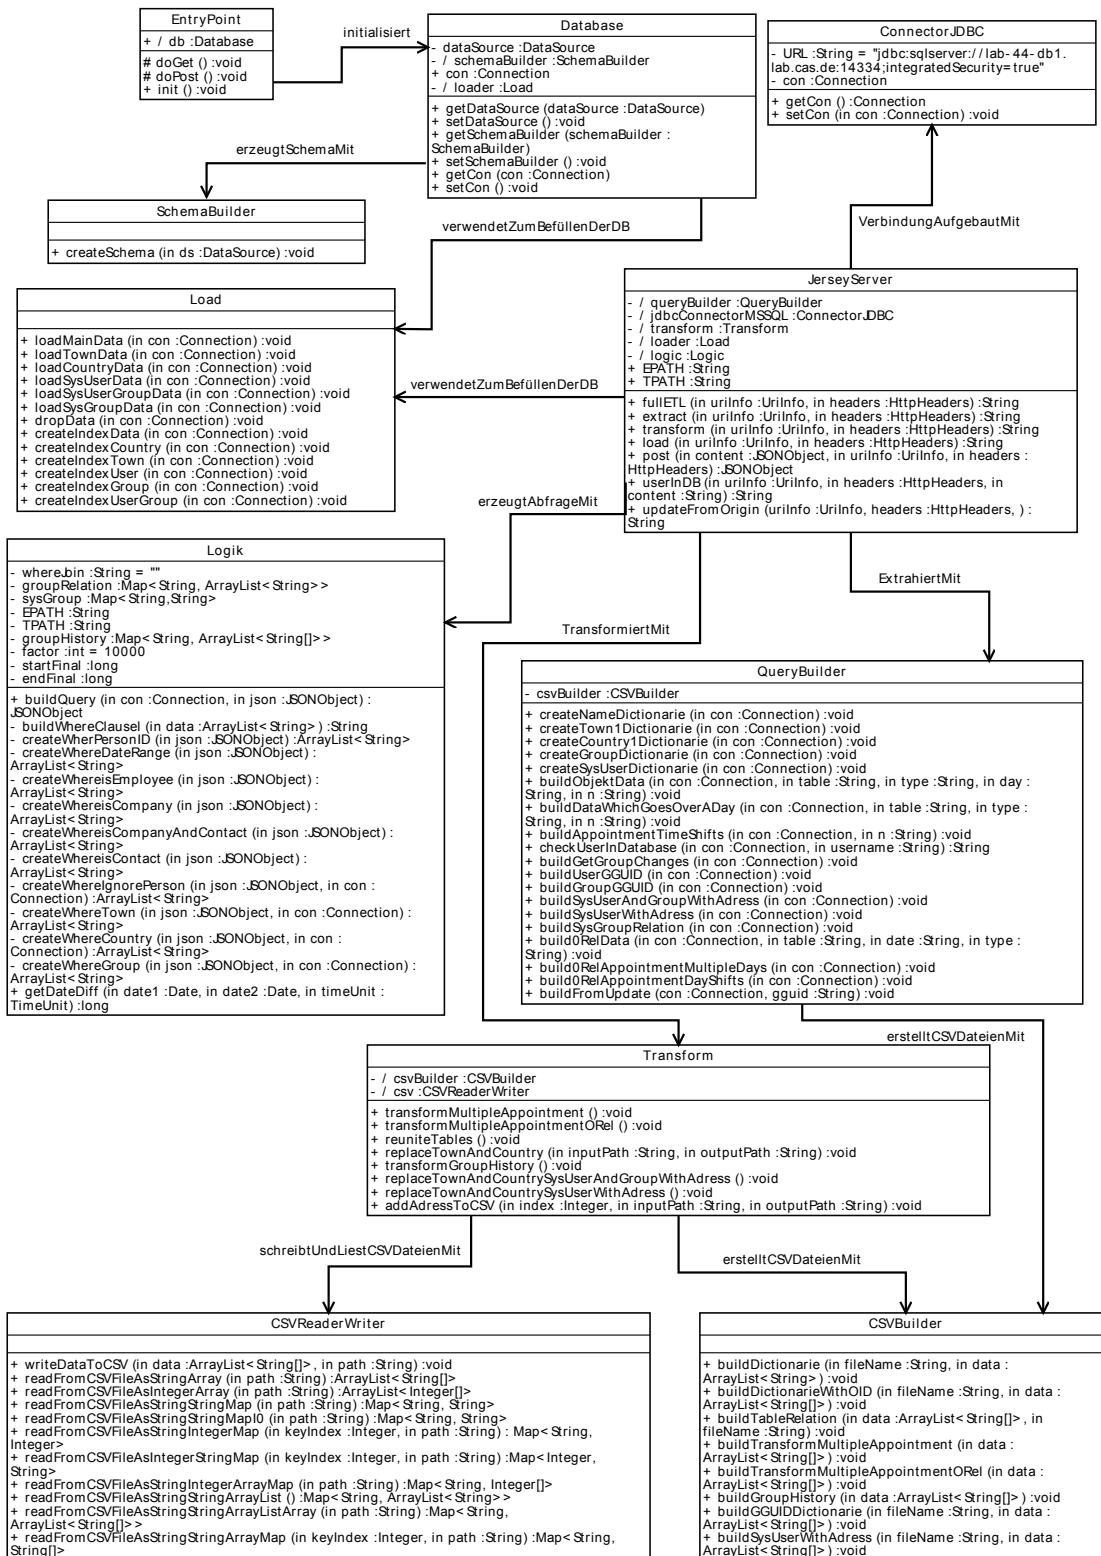


Abbildung 6.1: Server Klassendiagramm

und/oder HttpHeaders besitzen, die Abrufe von Metadaten der REST-Requests ermöglichen.

Neben den Methoden zu Beantwortung von REST-Requests, enthält die Klasse alle Objekte zur Durchführung des ETL-Prozesses. Die Klasse ConnectorJDBC besitzt ein Attribut namens con, welches den Verbindungsaufbau zum MSSQL Server, mithilfe von JDBC ermöglicht. Zur Extraktion der Daten aus dem MSSQL 2008 wird ein Objekt der Klasse QueryBuilder verwendet. Wie in der Abbildung zu sehen, werden für die verschiedenen Tabellen des neuen Schemas, eigene Methoden zur Verfügung gestellt. Methoden welche die Übergabewerte table, date und n besitzen, werden für die verschiedenen Verbindungsobjekte benötigt. Mithilfe des Parameters table, wird der Name der Tabelle in der MSSQL Datenbank übergeben. Der Parameter date gibt das Feld an, was für die Ermittlung des Datums verwendet werden soll. Um den Typ einer Verbindung zwischen Personen festzuhalten, wird der Parameter n verwendet, der eine Zahl zwischen eins und fünf beinhaltet. QueryBuilder verwendet ein Objekt vom Typ CSV-Builder, um die Ergebnisse in Dateien festzuhalten. Den Methoden wird als Übergabeparameter ein Dateiname, sowie die Daten selbst übergeben.

Die Klasse Transform enthält Attribute und Methoden zur Bearbeitung der CSV-Dateien. Weiterhin werden, die durch die Extraktionen gewonnenen CSV-Dateien, mithilfe eines CSVReaderWriter Objekts ausgelesen. Nach der Bearbeitung durch die Methoden der Transform-Klasse, werden die Daten wieder in CSV-Dateien abgelegt. CSVBuilder besitzt Methoden die zusätzliche Parameter zum schreiben aufweisen, die modifizierte Schreiboperationen erlauben. Wohingegen CSVReaderWriter mithilfe der Methode writeDataToCSV(), sowie den Parametern path und data allgemeine Schreiboperationen durchführt.

Mithilfe der Klasse Load, wird die Datenbank befüllt. Sie kann wie zuvor erwähnt von einem Database Objekt verwendet werden oder durch ein JerseyServer Objekt. Beim JerseyServer werden mit der Methode load(), die Methoden der Load-Klasse aufgerufen. In der Klasse Database werden sie im Konstruktor aufgerufen.

Die Logik Klasse enthält alle Attribute und Methoden, zur Beantwortung von Anfragen, durch den Nutzer. Zur Generierung der Bedingungen einer SQL-Abfrage, werden separate Methoden verwendet. Die jeweiligen Methoden werden nur gerufen, sobald die entsprechende Bedingung, in der vom Nutzer erhaltenen JSON Datei, vorhanden ist. Angesteuert wird der Bau einer Abfrage durch die Methode buildQuery().

6.2 Aufbau der Client.war

Einstiegspunkt in der Client.war ist die Klasse CasAnalyticUI. Sie ist von der Klasse UI abgeleitet. Die UI ist die oberste Komponente jeder Komponentenhierarchie. Es gibt eine Benutzeroberfläche für jede Vaadin-Instanz in einem Browser-Fenster. Ein UI Objekt kann entweder ein gesamtes Browser-Fenster (oder Tab) oder einen Teil einer HTML-Seite, wo eine Vaadin-Anwendung eingebettet ist, darstellen. Nachdem eine UI von der Anwendung erstellt wurde, wird es mit der Methode init(VaadinRequest) initialisiert. Zur Übersicht werden die Komponenten der Darstellung in die Klasse RootUI ausgelagert.

RootUI wird dabei von der CasAnalyticUI instanziert. Die Klasse RootUI beinhaltet das Anmeldefenster, sowie die Hauptansicht. Mithilfe der Methode buildLoginView() werden die Komponenten des Anmeldefensters zur UI hinzugefügt. Nach der Erzeugung der Komponenten, wird eine JerseyClient Klasse instanziert. Diese wird verwendet sobald der Nutzer IP, Port und einen Namen eingegeben hat und auf anmelden geklickt hat. Anschließend wird die Methode doPostRequestUserData() gerufen, um zu überprüfen ob der Nutzer im System existiert.

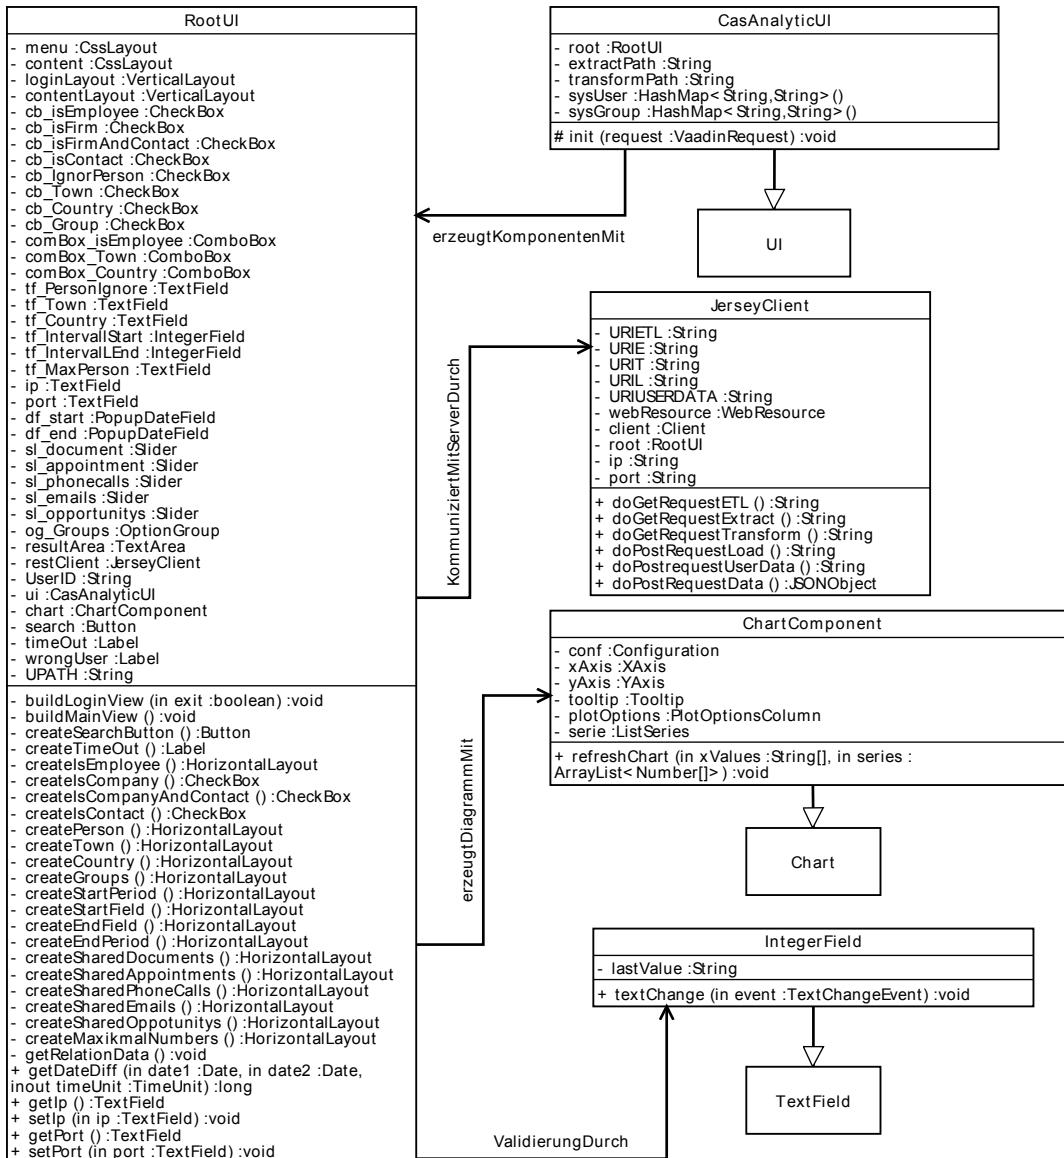


Abbildung 6.2: Client Klassendiagramm

Falls ja werden durch die Methode MainView() alle bisherigen Komponenten der UI entfernt und durch Komponenten des Hauptfensters ersetzt. Das JerseyClient Objekt wird direkt im Anschluss verwendet, um Mithilfe der Methode doPostRequestData() einen REST-Request an den Server zu senden. Dieser liefert das Ergebnis der Abfrage in einem JSON-Objekt zurück. Mit dessen einer ersten Darstellung des Diagramms erzeugt wird. Das Diagramm selbst besitzt eine eigene Klasse namens ChartComponent. Sie leitet sich von der Klasse Chart ab, die Teil der VaadinChart Bibliothek ist. Mithilfe der Methode refreshChart() wird das Diagramm bei Benutzerabfragen aktualisiert. Dazu werden ihr die Namen der Personen für die x-Achse übergeben, sowie die neuen Balkenwerte. Weiterhin wird für jedes Vaadin-Objekt das eine Element an der Oberfläche darstellen, eine separate Methode zur Erzeugung verwendet. Änderungen am Aussehen oder der Funktion, der jeweiligen Vaadin-Objekte, werden nur innerhalb der entsprechenden Methode vorgenommen.

An der Oberfläche gibt es Felder die nur Zahlen erwarten. Eingaben die nicht numerisch sind, werden durch den Einsatz der Klasse IntegerField verhindert. Diese erweitert die Klasse TextField. Sie besitzt einen Event-Listener, der jede Eingabe des Benutzers abfängt. Gibt der Nutzer nicht numerische Zeichen ein werden diese direkt wieder entfernt. Dadurch werden falsch Eingaben durch den Nutzer ausgeschlossen.

6.3 Erzeugung der Abfrage

Um Abfragen durch den Benutzer möglichst performant zu beantworten erfolgt die Erzeugung dynamisch. Das bedeutet die SQL-Abfrage an die Datenbank kann je nach Anforderung anders aufgebaut sein. Die Kernaufgabe ändert sich jedoch nie. Diese besteht aus der Bildung von Summen basierend auf verschiedenen Verbindungstypen. Zu Berücksichtigen ist das jede Abfrage einen Anfangs- und Endzeitpunkt enthält und somit beachtet werden muss. Nachdem festgestellt wurde wie viele Verbindungen von den jeweiligen Typen zu einer Person verlaufen wird zusätzlich die Gesamtsumme der Verbindungen zu einer Person gebildet. Die Summe wird zur Sortierung der Ergebnisse verwendet. Bei der Sortierung wird absteigend vorgegangen um die Personen mit den meisten Verbindungen zu der von der Suche ausgehend Person zu ermitteln. Das Ergebnis wird wiederum auf eine durch den Benutzer festgelegte Anzahl reduziert.

Zu diesen Kernfunktionalitäten können durch Angaben des Nutzers weitere hinzukommen. Eine von Ihnen ist die Gewichtung von Zeitpunkten. Der Ansatz zur Umsetzung der Gewichtung der Zeit wird anhand der Abbildung 6.3 erklärt. Die Abbildung zeigt ein Koordinatensystem mit den Gewichtung von einzelnen Zeitpunkten. Die x-Achse stellt den zeitlichen Verlauf dar. Während die y-Achse die Gewichtung darstellt. t_{start} markiert den Startzeitpunkt, wohingegen t_{end} den Endzeitpunkt angibt. Mithilfe von t_1 und t_2 werden Zeitspannen festgelegt, die differenziert zu gewichten sind. Um nun die Tage zu gewichten wurde der lineare Ansatz gewählt. Das bedeutet zwischen t_{start} und t_1 steigt die Relevanz stetig bis sie die 100 Prozent erreicht hat. Ab dort sind alle Tage wieder 100 Prozent relevant außer es ist ein t_2 angegeben worden. Falls ja wird ab t_2 linear fallend, jeder Tag bewertet.

Zur Berechnung der Gewichtung zu einem bestimmten Tag werden die folgenden zwei Variablen verwenden:

$$f_1 = \frac{1}{t_1 - t_{start}} \quad (6.1)$$

$$f_2 = \frac{1}{t_{end} - t_2} \quad (6.2)$$

Dabei wird wie folgt vorgegangen. t_{start} markiert Tag. Aufsteigend zählend wird jeder Tag bis t_1 mit der Variabel f_1 multipliziert. Für den Zeitpunkt t_2 wird die Summe der Tage in der Zeitspanne zwischen t_2 und t_{end} verwendet. Die Summe wird mit jedem weiteren Tag um 1 vermindert bis zum Zeitpunkt t_{end} , der 0 darstellt. Bei jedem Schritt wird der Tag mit der Variablen f_2 multipliziert.

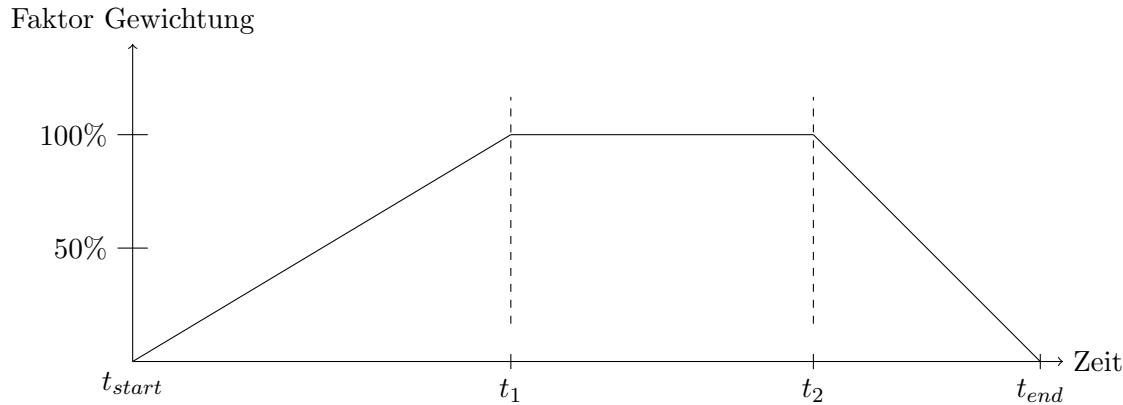


Abbildung 6.3: Gewichtung der Zeit

Neben der Gewichtung der Zeit lassen sich die jeweiligen Verbindungstypen unterschiedlich gewichten. Bei einer Abweichung von 100 Prozent wird die Summe des jeweiligen Verbindungstypen um die durch den Nutzer bestimmten Prozentsatz verringert.

Die restlichen Parameter dienen der Filterungen und werden je nach Nutzer-Eingabe zu den Bedingungen der SQL-Abfrage hinzugenommen. Unter Ihnen gibt es eine Bedingung zuvor Ermittelt werden muss und daher näher beschrieben wird. Dabei handelt es sich um das ausschließen von Gruppen, da sich Ihre Zusammensetzung über die Zeit variabel ist. Dazu wird die Tabelle UserGroup verwendet. Dabei wird wie folgendermaßen vorgegangen. Zuerst wird die Ergebnismenge auf die ausgewählten Gruppen reduziert. Anschließend wird für jede Gruppe ein eigener Container erzeugt, der alle Personen der Gruppe enthält. Liegt nun das Feld Date nach dem Anfangszeitpunkt der Abfrage und die Spalte Action enthält eine 1, wird der Container um diese Person reduziert. Enthält die Spalte Action eine 0 wird die Person zum Container hinzugefügt. Die 1 in der Spalte Action bedeutet das die Person zu dem in der Spalte Date angegeben Datum die Gruppe verlassen hat. Eine 0 bedeutet das die Person zu dem angegeben Datum hinzukam. Dadurch wird die Zusammensetzung zum Anfangszeitpunkt wiederhergestellt. Mithilfe der Personen aus den Container wird nun die SQL-Abfrage um weitere Bedingungen erweitert.

Zu beachten ist natürlich das innerhalb des Zeitraums Gruppenveränderungen stattgefunden haben können, diese jedoch nicht zu Berücksichtigen sind. Es kann jeweils nur ein bestimmter Zeitpunkt für die Betrachtung berücksichtigt werden. In diesem Fall wurde der Anfangszeitpunkt gewählt.

6.4 ETL Prozess

Um an die notwendigen Daten zu gelangen werden zuerst die Informationen aus der alten Datenbank extrahiert. Dazu wird ein Verbund gebildet der die Tupeln der Tabellen verschmelzen lässt. Die manuellen erstellten Verbindungen in der alten Datenbank werden mithilfe der Tabelle TableRelation festgehalten. Zur Gewinnung dieser Verbindungen wird als erstes eine SQL-Abfrage definiert die für jede der Tabellen gwOpportunity, gwPhoneCall0, Document0, EmailStore0 und Appointment0 separat ausgeführt wird.

Mithilfe des ersten Verbundes zwischen SysUser und Adresse wird die Adresse einer Person ermittelt. Anschließend wird durch einen Verbund der TableRelation und SysUser alle Tabellen ermittelt die mit der Person eine Verbindung besitzen. Der nächste Verbund ist zwischen TableRealtion und einer der fünf zuvor genannten Tabellen. Um festzustellen welche Personen auch mit beispielsweise einem Dokument arbeiten zu ermitteln wird ein weiterer Verbund mit der passenden ORel-Tabelle ausgeführt. In der ORel-Tabelle kann die OID positiv sowie negativ sein. Bei einem negativen Wert stellt die OID eine GID der Tabelle SysGroup dar. Zur Auflösung der Gruppe in einzelne Personen werden folgende Verbunde gebildet. Zuerst zwischen SysGroup und SysGroupMember um alle Personen die zu einer Gruppe gehören zu erhalten. Anschließend zwischen SysGroupMember und SysUser um die OID der Person zu erhalten.

Nachdem alle Information in einem Verbund vorhanden sind werden lediglich drei Informationen des Gesamten Verbundes behalten. Zu einem die OID des SysUser von dem die Suche ausgeht. Zum anderen das Datum welches durch das Objekt welches die Personen verbindet ermittelt wird. Weiterhin wird die zweite OID durch den Verbund mit einer zweiten SysUser Tabelle behalten. Zum Schluss wird manuell eine vierte Information beigefügt die besagt welchem Objekt die Tupel entstammt.

Für den Sonderfall das ein Datum über mehrere Tage geht wird eine fünfte Spalte hinzugefügt welche den Zeitraum in Tagen beinhaltet. Zur Beschaffung der geschobenen Termine wird genau wie in der Konzeption beschrieben verfahren.

Zur Ermittlung direkter Verbindungen zwischen Personen wird lediglich ein Verbund aus zwei ORel-Tabellen eines Objektes gebildet. Dieser Verbund beinhaltet bereits die OIDs der beiden Personen. Zur Ermittlung des Datums wird noch ein Verbund mit der Tabelle des Objektes gebildet. Die negativen OIDs werden genauso wie oben beschrieben aufgelöst.

Jede Antwort einer SQL-Abfrage zur Gewinnung von Daten wird in einer SCV-Datei direkt auf dem Tomcat Server abgelegt. Diese CSV Dateien stellen die Grundlage der Transformation dar. Jede dieser Dateien beinhaltet Verbindungen zwischen Personen in der Form wie sie Abbildung 6.4 zeigt.

```

1703 "22", "5238", "3", "42", "1", "1", "1", "Karlsruhe", "Deutschland"
1704 "22", "5238", "3", "42", "1", "1", "1", "Karlsruhe", "Deutschland"
1705 "22", "5238", "3", "11", "1", "1", "1", "Karlsruhe", "Deutschland"
1706 "22", "5238", "3", "123", "1", "1", "1", "Karlsruhe", "Deutschland"
1707 "22", "null", "3", "123", "1", "1", "1", "Karlsruhe", "Deutschland"
1708 "22", "5238", "3", "110", "1", "1", "1", "Karlsruhe", "Deutschland", "3"
1709 "22", "5238", "3", "20", " ", " "
1710 "22", "5238", "3", "20", null, null, null, null, null

```

Abbildung 6.4: Ausschnitt einer CSV-Datei mit Daten der Extraktion

Alle CSV-Dateien werden auf die in Abbildung 6.4 zu sehenden Ungereimtheiten untersucht. Dabei werden Zeilen wo die letzten fünf Werte fehlen über die die OID (die vierte Zahl) die Adresse ergänzt. Bei null Werten wird überprüft ob wirklich keine Adresse vorhanden ist falls doch werden diese ebenfalls ergänzt. Wenn wie in Zeile 1707 zu sehen eine null Anstatt einem Datum steht wird die Zeile entfernt. Falls wie in Zeile 1708 ein zusätzlicher zehnter Wert vorhanden ist, bedeutet das die Verbindung über mehrere Tage geht. Die Zeile bleibt bestehen jedoch wird der letzte Wert entfernt. Die Zahl wird jedoch noch verwendet um die weiteren Zeilen mit aufsteigendem Datum zu erzeugen. Nach der Beseitigung von Anomalien werden noch die Städte und Länder durch ihre jeweilige ID aus der Tabelle Town und Country ersetzt.

Die veränderten Daten werden wieder in CSV-Dateien abgelegt die gleich bezeichnet sind allerdings noch den Zusatz „_transf“ besitzen der Sie als Transformiert markiert. Diese Dateien werden anschließend in eine CSV-Datei zusammengeführt. Bei der Zusammenführung sind zum ersten mal alle Daten gleichzeitig in der Anwendung weshalb an dieser Stelle alle Duplikate beseitigt werden. Weiterhin werden die Zeilen sortiert. Dabei wird mit zwei Kriterien sortiert. Das erste Kriterium ist der Erste Wert die OID der Person von dem die Suche ausgeht. Wenn hierbei gleiche Werte verglichen werden wird das zweite Feld(Datum) herangezogen. Nachdem alle Zeilen sortiert und von Duplikaten bereinigt sind werden alle Zeilen in einer CSV-Datei abgelegt.

Diese Datei wird bei jedem Start des Tomcats dazu verwendet einen Bulk-Load für die H2-Datenbank zu initialisieren. Nachdem die Datenbank mit Daten befüllt wurde werden abschließend die Indizes erzeugt.

6.5 Aktualisierung des Datenbestandes ...Progress

Wie zuvor in Abschnitt 5.5 behandelt wird die Aktualisierung unseres Datenbestandes von CAS genesisWorld angestoßen. Zur Umsetzung ist die Definition einer COM-Komponente notwendig. Dazu wird eine DLL-Datei angelegt. Diese muss Namenskonventionen einhalten. Dateien die aufgenommen werden sollen, müssen mit dem Prefix „pGSAxExtCustomServerDataPlugin“ beginnen. Die DLL-Datei ist in der RegisterSDKDataPlugIns.xml hinterlegt, damit der Anwendungsserver beim Start unser Plugin findet. Weiterhin ist in der XML-Datei eine Tabelle paarweise mit einer DLL angegeben. Dadurch wird ein Plugin auf eine Datenbanktabelle registriert und bekommt alle betreffenden Änderungen mit.

Die Programmbibliothek selbst ist in Delphi realisiert. Abbildung 6.5 zeigt die Struktur der DLL-Datei. Die Klasse selbst implementiert sechs verschiedene Schnittstellen. Co-mObj stellt Funktionen zur Erstellung und Bearbeitung von COM-Objekten zur Verfügung. Um Funktionalitäten von CAS genesisWorld vollständig zu Nutzen wird die ActiveX Schnittstelle benötigt. Wie bereits behandelt findet die Übertragung der Daten über das REST-Protokoll statt, wofür die idHttp Schnittstelle verwendet wird. Um Konvertierungen der vom Anwendungsserver erhaltenen Binärwerte vorzunehmen, werden die Funktionen der Schnittstellen CAS_ToolsCOM und CAS_VarType14Fix genutzt. Die eigentliche Kernfunktionalität, dass Abfangen der geänderten Daten, sind durch die Funktionen der IGWSDKDataPlugin Schnittstelle möglich.

Die Funktionen der Abbildung 6.5 gehören von BeforeAddNew() bis AfterUndelete() zur IGWSDKDataPlugin Schnittstelle. Es sind zwar alle Funktionen in der DLL implementiert, allerdings werden nur die Funktionen die mit After beginnen auch mit Logik hinterlegt. Für unser System reicht es nämlich aus, über Änderungen im Nachhinein benachrichtigt zu werden. Diese Funktionen enthalten alle die gleiche Logik und unterscheiden sich lediglich in den Übergabeparameter.

Die Logik innerhalb der Funktionen sieht wie folgt aus. Eine Veränderungen der Datensätze wird vom Nutzer angestoßen. Das Plugin wird nach den Änderungen aufgerufen. Die entsprechende Funktion erhält die GGUID der Tupel, den Namen der Spalte, sowie die veränderten Werte. Anschließend wird überprüft ob die Änderungen für unser System von Relevanz ist. Dafür wird überprüft ob die betroffene Spalte zu den in der ETL-Phase betroffenen Spalten gehört. Falls ja wird die aGGUID in einen String konvertiert. Weiterhin werden die Variablen einer idHttp Variable gesetzt. Dazu werden Werte wie die URI oder HTTP-Header zugewiesen. Sobald alle Daten in der idHttp Variable vorhanden sind, wird ein POST-Request an unser System übermittelt.

Der POST-Request enthält lediglich die GGUID und die Art der Operation die auf den Daten ausgeführt wurde. Bei einem Update beispielsweise wird ein Header mit einem Key-Value wie „Operator:Update“ übermittelt. In unserem Server wird lediglich überprüft ob

der Wert der geändert wurde bereits existiert. Falls ja wird er gelöscht und neu beschafft. Falls nein wird er nur besorgt.

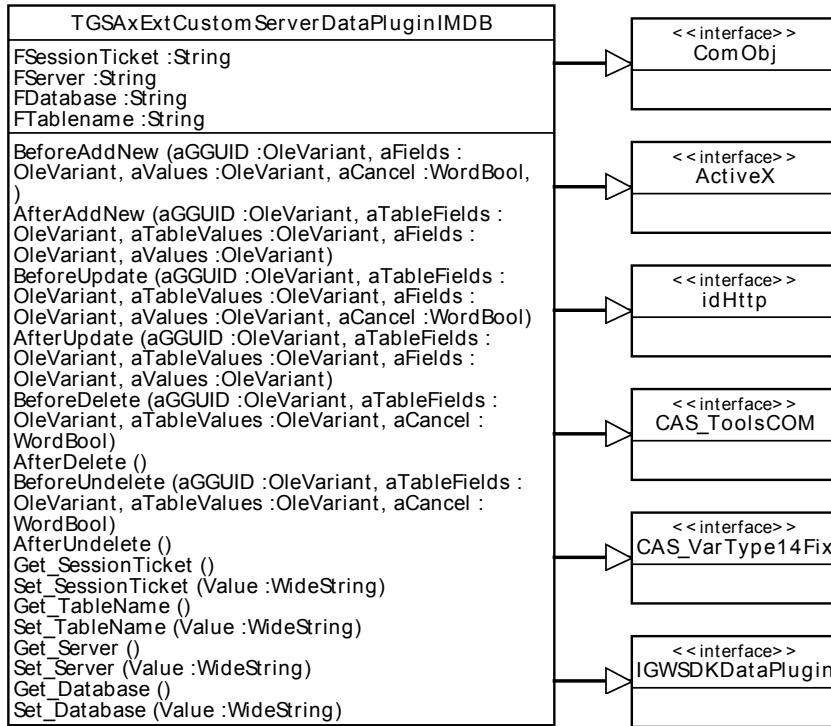


Abbildung 6.5: Klassendiagramm Plugin

6.6 Oberfläche

In diesem Abschnitt wird die Umsetzung auf der Darstellungsebene erörtert. Den Einstiegspunkt für Nutzer stellt das in Abbildung 6.6 zu sehende Anmeldefenster dar. Der Hintergrund der Webseite ist in einem dunklen grau Gestaltet, um sich von dem weißen Hintergrund der Bedienelemente abzuheben. Zur Identifikation des Systems mit der Firma ist dessen Logo im linken Teil dargestellt. Im rechten Teil des Fensters existieren drei Eingabefelder. Zuerst ein Feld zur Eingabe der IP-Adresse des Server. Die dazugehörige Portnummer wird im darauf folgenden Feld eingegeben. Das dritte Feld ist für den Namen des Nutzers vorgesehen, der den Ausgangspunkt der Analyse darstellt. Abschließend wird ganz klassisch ein Button zum fortfahren auf der Webseite eingesetzt. Falls allerdings der eingegebene Nutzernname nicht existiert wird eine Warnmeldung direkt über dem dafür vorgesehenen Feld ausgegeben.

Das Hauptfenster wurde vom Aufbau wie in Abschnitt 5.6 beschrieben umgesetzt. Im oberen Bereich findet sich eine Leiste, die an Produkte wie Microsoft Office angelegt ist. Dies schafft ein vertrautes Gefühl mit der Oberfläche, da auf bekanntem aufgebaut werden kann. Die Leiste ist in vier Bereiche gegliedert. Der erste Bereich, ganz links, dient der Gewichtung von Suchkriterien und der Anfragestellung. Aufgrund der Gewichtung in Prozent ist ein fester Wertebereich von 0 bis 100 vorgegeben. Textfelder eignen sich daher weniger, da sie beliebige Eingaben ermöglichen. Der Einsatz von Reglern bietet eine einfachere und selbsterklärende Form der Bedienung. Der begrenzte sowie kleine Wertebereich führt zu der Entscheidung. Zum stellen der Anfrage wird ein einfacher Button eingesetzt. Direkt unter dem Button befindet sich Text, der zur Ausgabe der benötigten Zeit vorgesehen ist.

Der zweite Bereich in der Mitte dient zeitlichen Anpassungen. Das erste und dritte Feld können zur Veränderung der Zeitspanne verwendet werden. Sie beinhalten den Anfangs-

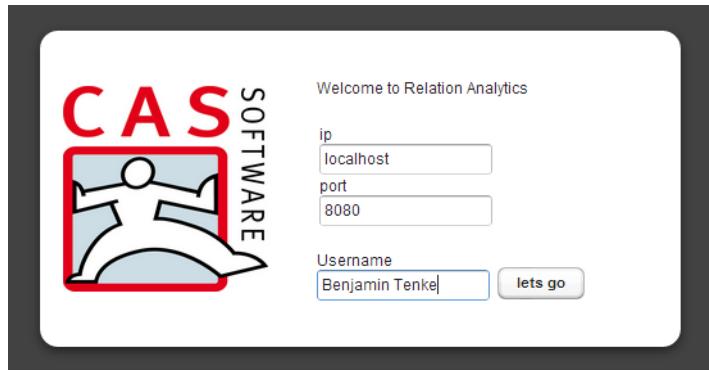


Abbildung 6.6: Oberfläche des Systems

und Endzeitpunkt der Betrachtung. Händische Eingaben sind eher schlecht für die Bedienbarkeit weswegen ein sogenannter Datumspicker eingesetzt wird. Dieser befindet sich direkt neben dem Textfeld und öffnet sich nach einem Klick auf das Symbol. Er stellt einen grafischen Kalender dar aus dem durch Klicken auf ein Tag das Datum bestimmt werden kann. Die Möglichkeit zur Eingabe durch direktes Ändern des Textes bleibt allerdings weiterhin erhalten. Die anderen beiden Felder sind für die Gewichtung der Zeit vorgesehen. In Abbildung 6.3 werden die Zeitpunkt bis zu dem differenziert gewichtet werden soll mit t_1 und t_2 bezeichnet. Diese Zeitpunkte können mithilfe der Textfelder bestimmt werden. Das obere Feld ist für t_1 . Hier kann die Zeitspanne zwischen t_{start} und t_1 in Tagen festgelegt werden. Für t_{ende} und t_2 verhält es sich mit dem unteren Feld ebenso.

Bis auf die Gruppenfilterung sind im dritten Bereich alle restlichen Filtermöglichkeiten vorhanden. Mithilfe von Checkboxen kann der Nutzer festlegen welche Filterungen auf die Analyse angewendet werden sollten. Neben der Filterung durch bestimmte Personen, Länder, Städte usw. ist hier eine Begrenzung der Ergebnismenge umgesetzt. Im untersten Feld kann der Nutzer diese bestimmen.

Der Bereich ganz rechts in der Leiste ist für den Ausschluss von Gruppen vorgesehen. Hier werden alle Gruppen im System mit einer Checkbox und einem Namen dargestellt. Dabei können beliebig viele Gruppen ausgewählt werden. Da die Anzahl der Gruppen überschaubar ist entschied man sich alle anzuzeigen anstatt einer manuellen Eingabe durch den Nutzer. Das hat auch den Vorteil, dass der Benutzer Gruppen sieht die er eventuell nicht exakt beim Namen kennt.

Den zentralen Bereich des Fensters stellt das Diagramm dar. Die Balken selbst sind fünf verschiedene Elemente unterteilt. Jedes Element wird dabei durch eine andere Farbe dargestellt. Die fünf Elemente sind die verschiedenen Merkmale. Die Zuordnung der Farbe zu dem jeweiligen Merkmal wird über eine Legende im unteren Bereich des Fensters umgesetzt. Eine Besonderheit ist, dass durch einen Klick auf eine der Farben, das jeweilige Merkmal von der Darstellung ausgeschlossen wird. Beispielsweise kann der Nutzer auf die blaue Farbe neben dem Dokument klicken, was einen Neuaufbau des Diagramms, ohne dieses Merkmal bewirkt. Durch diesen Ausschluss wird allerdings keine neue Abfrage gesendet. Das bedeutet die Reihenfolge in der Personen angezeigt werden bleibt gleich, sowie die Datenbasis. Mit einem wiederholten Klick lässt sich das ganze Rückgängig machen. Zusätzlich zu der Y-Achse, die eine Gesamtpunktzahl aufzeigt, kann der jeweilige Anteil eines Merkmals betrachtet werden. Dies geschieht durch einfaches Platzieren des Mauszeigers auf dem jeweiligen Bereich des Balkens. Dadurch öffnet sich ein Tooltip welches die Anzahl der Punkte im Verhältnis zur Gesamtpunktzahl zeigt.

Die Anfragestellung erfolgt in der Regel mit dem dafür vorgesehenen Button. Die Regler und das Datum lösen jedoch bei Veränderungen automatisch eine neue Abfrage aus. Dies



Abbildung 6.7: Oberfläche des Systems

soll die die hohe Antwortgeschwindigkeit des Systems untermaßen. Das Datum sowie die Gewichtung wurden dafür ausgewählt da diese die am meist benutzen Konfigurationsmöglichkeiten darstellen.

7. Zusammenfassung

...

7.1 Ergebnisanalyse

Einer der wichtigsten Anforderungen ist die geringe Abfragegeschwindigkeit. Tabelle ?? zeigt, dass man dieser Forderung gerecht wird. Ebenfalls deutlich zu erkennen, ist die Auswirkung des geänderten Schemas. Der Sprung von 98.000 ms auf 350 ms, ist durch die Reduktion zu erklären. Im neuen Schema existieren weniger Tabellen und weniger Tupeln. Außerdem ist im neuen Schema kein Verbund mehr notwendig, der sehr rechenintensiv sein kann. Allerdings muss einem klar sein, dass solche Maßnahmen, wie sie im Schema-design ergriffen wurden, weitreichende Folgen haben. Eine davon ist eine sehr schlechte Erweiterbarkeit des Schemas. Im momentanen Schema können lediglich Spalten hinzugezogen werden, dessen Inhalt in allen Merkmalen vorhanden ist. Außerdem würde für jede Spalte weitere 18 Mio. Werte hinzukommen. Hinzunahme von Merkmal spezifischen Attributen führt ebenfalls zu hohem Änderungsaufwand. Die Konsequenz wäre eine Normalisierung die aus der data-Tabelle mehrere Tabellen macht. Dies würde den Einsatz von Verbundoperatoren erfordern. Dadurch würde die Abfragezeit wieder steigen. Allerdings wären wesentlich weniger Verbundoperatoren nötig als im alten Schema. Aufgrund dessen ist trotzdem mit einer deutlichen geringeren Abfragegeschwindigkeit zu rechnen.

Versuchskomponente	Zeit in ms
MSSQL Datenbank & Altes Schema	98000
MSSQL Datenbank & Neues Schema	350
H2 Datenbank & Neues Schema	80

Tabelle 7.1: Abfragegeschwindigkeit Vergleich

Bei Änderungen, die eine Steigerung der Komplexität mit sich bringen, stellt sich eine Frage. Ist die Datenbank nur aufgrund des geänderten Schemas deutlich schneller? Um dieser Frage nachzugehen wurden einige Tests durchgeführt. Abbildung 7.1 zeigt die Ergebnisse dieser Testreihen. Alle Test wurden auf einem Rechner durchgeführt. Dieser simulierte den Zugriff von 100 gleichzeitigen Benutzern, mithilfe von Multithreading. Die in den Diagrammen angegebene Zeit bezieht sich somit auf die Ausführung aller 100 Abfragen. Jeder simulierte Benutzer führt somit die auf der y Achse angegebene Anweisung aus. Beim

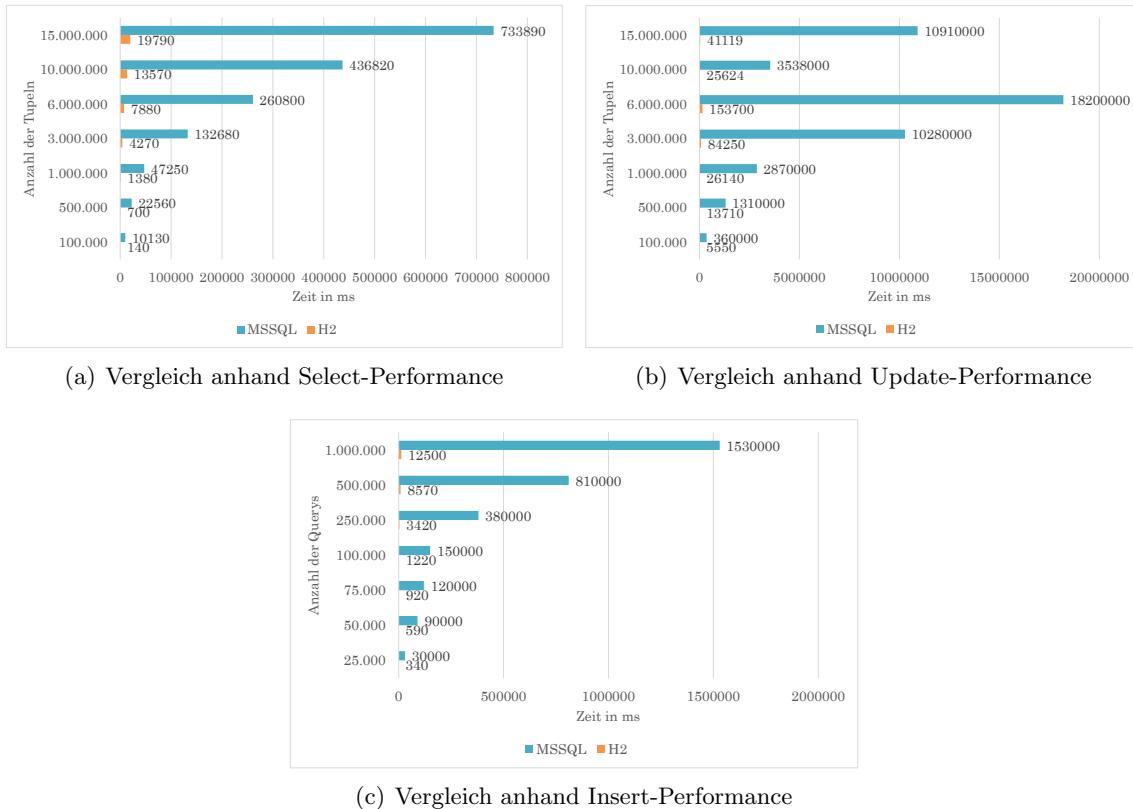


Abbildung 7.1: Abfragegeschwindigkeit Vergleich

obersten Balken in (a) sind es beispielsweise 15 Mio. SELECT-Anweisungen pro Benutzer. In (b) sind es hingegen 15 Mio. Update-Anweisungen. Die Insert-Anweisungen zeigt (c).

Die Ergebnisse der Tests zeigen, dass die H2-Datenbank deutlich schneller ist als die MSSQL Datenbank. Der H2 ist bei SELECT-Anweisungen, um den Faktor 37 schneller. Bei Update-Anweisungen sogar um den Faktor 117 schneller. Ebenso bei Insert-Anweisungen, die einen Unterschied um den Faktor 124 aufweisen. Darauf lässt sich schließen, dass die H2-Datenbank mit ihren In-Memory-Tabellen deutlich schneller ist. Diese Geschwindigkeit wird durch den Verzicht auf Persistenz erlangt. In analytischen Systemen wo fast nur Leseoperationen durchgeführt werden stellt die mangelnde Persistenz kein großes Defizit dar.

7.2 Handlungsempfehlungen

Des Weiteren soll dargelegt werden, welche Möglichkeiten sich bei der Weiterführung des Projektes bieten und welche Schwierigkeiten auftreten könnten.

Das momentane System ermittelt die Personen, die den stärksten Zusammenhang zueinander aufweisen, aufgrund der Anzahl der Verbindungen zwischen ihnen. Dabei wird lediglich die Häufigkeit gewertet. Um die Stärke einer Beziehung zu bewerten könnten zusätzliche Regeln eingeführt werden. Diese Regeln müssten auf psychologischen Erkenntnissen und Erfahrungswerten aufbauen. Durch Regeln könnte die Aussagekraft des Ergebnisses weiter steigen.

7.3 Ergebnis

...

7.4 Ausblick

...

Literaturverzeichnis

- [AMF06] Daniel Abadi, Samuel Madden und Miguel Ferreira: *Integrating Compression and Execution in Column-oriented Database Systems*. In: *Proceedings of the 2006 ACM SIGMOD International Conference on Management of Data*, SIGMOD '06, Seiten 671–682, New York, NY, USA, 2006. ACM, ISBN 1-59593-434-0. <http://doi.acm.org/10.1145/1142473.1142548>.
- [ASK07] Aditya Agarwal, Mark Slee und Marc Kwiatkowski: *Thrift: Scalable Cross-Language Services Implementation*. Technischer Bericht, Facebook, April 2007. <http://incubator.apache.org/thrift/static/thrift-20070401.pdf>.
- [CD10] Kristina Chodorow und Michael Dirolf: *MongoDB - The Definitive Guide: Powerful and Scalable Data Storage.*, Seiten 1–10, 16–17, 101–104, 127–129, 143–147. O'Reilly, 2010, ISBN 978-1-449-38156-1.
- [CDG⁺06] Fay Chang, Jeffrey Dean, Sanjay Ghemawat, Wilson C. Hsieh, Deborah A. Wallach, Mike Burrows, Tushar Chandra, Andrew Fikes und Robert E. Gruber: *Bigtable: A Distributed Storage System for Structured Data*. In: *Proceedings of the 7th USENIX Symposium on Operating Systems Design and Implementation - Volume 7*, OSDI '06, Seiten 1–15, Berkeley, CA, USA, 2006. USENIX Association. <http://dl.acm.org/citation.cfm?id=1267308.1267323>.
- [Cor13] Janssen Cory: *SQL Server*. 2013. <http://www.techopedia.com/definition/1243/sql-server>, [Online;accessed 8-November-2013].
- [Cou13] CouchDB: *Technical Overview*. 2013. <http://docs.couchdb.org/en/latest/intro/overview.html>, Online;accessed 27-November-2013.
- [CSA13] CAS-Software-AG: *CAS Products WebServices SDK x5 documentation*. 2013. <https://partnerportal.cas.de/WebServicesSDK/pages/architecture/overview.html>, [Online;accessed 4-November-2013].
- [DG08] Jeffrey Dean und Sanjay Ghemawat: *MapReduce: Simplified Data Processing on Large Clusters*. Commun. ACM, 51(1):107–113, Januar 2008, ISSN 0001-0782. <http://doi.acm.org/10.1145/1327452.1327492>.
- [Dr.00] A.Brewer Dr.Eric: *PODC keynote*. 2000. <http://www.cs.berkeley.edu/~brewer/cs262b-2004/PODC-keynote.pdf>, Online;accessed 27-November-2013.
- [ESHB11] Shaker H. Ali El-Sappagh, Abdeltawab M. Ahmed Hendawi und Ali Hamed El Bastawissy: *A proposed model for data warehouse {ETL} processes*. Journal of King Saud University - Computer and Information Sciences, 23(2):91 – 104, 2011, ISSN 1319-1578. <http://www.sciencedirect.com/science/article/pii/S131915781100019X>.

- [GL02] Seth Gilbert und Nancy Lynch: *Brewer's Conjecture and the Feasibility of Consistent, Available, Partition-tolerant Web Services*. SIGACT News, 33(2):51–59, Juni 2002, ISSN 0163-5700. <http://doi.acm.org/10.1145/564585.564601>.
- [HKJR10] Patrick Hunt, Mahadev Konar, Flavio P. Junqueira und Benjamin Reed: *Zoo-Keeper: Wait-free Coordination for Internet-scale Systems*. In: *Proceedings of the 2010 USENIX Conference on USENIX Annual Technical Conference*, USENIXATC'10, Seiten 1–11, Berkeley, CA, USA, 2010. USENIX Association. <http://dl.acm.org/citation.cfm?id=1855840.1855851>.
- [KKN⁺08] Robert Kallman, Hideaki Kimura, Jonathan Atkins, Andrew Pavlo, Alexander Rasin, Stanley Zdonik, Evan P. C. Jones, Samuel Madden, Michael Stonebraker, Yang Zhang, John Hugg und Daniel J. Abadi: *H-Store: a High-Performance, Distributed Main Memory Transaction Processing System*. Proc. VLDB Endow., 1(2):1496–1499, 2008, ISSN 2150-8097. <http://hstore.cs.brown.edu/papers/hstore-demo.pdf>.
- [Lam78] Leslie Lamport: *Time, Clocks, and the Ordering of Events in a Distributed System*. Commun. ACM, 21(7):558–565, Juli 1978, ISSN 0001-0782. <http://doi.acm.org/10.1145/359545.359563>.
- [LLS13] Justin J. Levandoski, Per Ake Larson und Radu Stoica: *Identifying hot and cold data in main-memory databases*. 2013 IEEE 29th International Conference on Data Engineering (ICDE), 0:26–37, 2013, ISSN 1063-6382.
- [LM10] Avinash Lakshman und Prashant Malik: *Cassandra: a decentralized structured storage system*. SIGOPS Oper. Syst. Rev., 44(2):1–5, April 2010, ISSN 0163-5980. <http://doi.acm.org/10.1145/1773912.1773922>.
- [Loo01] Peter Loos: *Go to COM : [das Objektmodell im Detail betrachtet; COM von Grund auf; beispielorientiert]*. Go-To-Reihe. Addison-Wesley, München [u.a.], 2001, ISBN 3-8273-1678-2.
- [Pla13] Hasso Plattner: *A Course in In-Memory Data Management : The Inner Mechanics of In-Memory Databases*, 2013, ISBN 978-3-642-36524-9. <http://dx.doi.org/10.1007/978-3-642-36524-9>.
- [Rup13] Chris Rupp: *Systemanalyse kompakt*. Springer Vieweg, Berlin, 3. aufl. Auflage, 2013, ISBN 978-3-642-35445-8.
- [RWE13] Ian Robinson, Jim Webber und Emil Eifrem: *Graph databases : [compliments of Neo technology]*. O'Reilly, Beijing, 1. ed. Auflage, 2013, ISBN 978-1-449-35626-2; 1-449-35626-5. http://deposit.d-nb.de/cgi-bin/dokserv?id=4300566&prov=M&dok_var=1&dok_ext=htm.
- [Seg13] Karl Seguin: *The Little Redis Book*. 2013. <http://openmymind.net/redis.pdf>, [Online; accessed 11-November-2013].
- [SKRC10] Konstantin Shvachko, Hairong Kuang, Sanjay Radia und Robert Chansler: *The Hadoop Distributed File System*. In: *Proceedings of the 2010 IEEE 26th Symposium on Mass Storage Systems and Technologies (MSST)*, MSST '10, Seiten 1–10, Washington, DC, USA, 2010. IEEE Computer Society, ISBN 978-1-4244-7152-2. <http://dx.doi.org/10.1109/MSST.2010.5496972>.
- [SSH11] Gunter Saake, Kai Uwe Sattler und Andreas Heuer: *Datenbanken : Implementierungstechniken*. mitp, Heidelberg, 3. aufl. Auflage, 2011, ISBN 978-3-8266-9156-0; 3-8266-9156-3. <http://deposit.d-nb.de/>

- cgi-bin/dokserv?id=3872660&prov=M&dok_var=1&dok_ext=htm;http://d-nb.info/1014629934/04, Seiten : 176 - 182.
- [Vai13] G. Vaish: *Getting Started with Nosql*, Seiten 25–49. Packt Publishing, Limited, 2013, ISBN 9781849694995.
- [Vol13a] Project Voldemort: *Voldemort a distributed database*. 2013. <http://www.project-voldemort.com/voldemort/>, [Online;accessed 13-November-2013].
- [Vol13b] VoltDB: *Application Brief*. 2013. http://voltdb.com/downloads/app_briefs/voltdb_transactions.pdf, [Online;accessed 14-November-2013].
- [Vol13c] VoltDB: *Technical Overview*. 2013. http://voltdb.com/downloads/datasheets_collateral/technical_overview.pdf, [Online;accessed 14-November-2013].

